



佛山大学
FOSHAN UNIVERSITY



计算机与人工智能学院
School of Computer Science and Artificial Intelligence

2025

NLP中的机器学习

Machine Learning for Natural Language Processing

任课教师：陈荟慧

目录 CONTENTS



01

NLP
机器学习流
程

02

NLP
常见机器学
习方法


03

NLP
文本分类应
用



机器学习的workflow

- 步骤1：收集数据
- 步骤2：探索你的数据
- 步骤2.5：选择一个模型*
- 步骤3：准备数据
- 步骤4：构建、训练和评估你的模型
- 步骤5：调优超参数
- 步骤6：部署模型



$$A = \pi r^2$$



机器学习训练的要素

- 1.数据
 - 数据是机器学习发展的核心
- 2.模型
 - 目标：得到一个满意的模型
- 3.损失函数
- 4.训练
- 5.训练误差
- 6.测试误差（实际误差）





机器学习的重要的四类问题

- 1.预测 (Prediction)
 - 回归
- 2.聚类 (Clustering)
 - K-Means
- 3.分类 (Classification)
 - SVM
- 4.降维 (Dimensionality reduction)
 - PCA





有监督学习

- 有监督学习是从标签化训练数据集中推断出函数的机器学习任务。
 - 支持向量机 (Support Vector Machines)
 - 线性回归 (linear regression)
 - 逻辑回归 (logistic regression)
 - 朴素贝叶斯 (naive Bayes)
 - 线性判别分析 (linear discriminant analysis)
 - 决策树 (decision trees)
 - K-近邻 (k-nearest neighbor algorithm)
 - 多层感知器 (Multilayer perceptron)





无监督学习


- 根据类别未知(没有被标记)的训练样本解决模式识别中的各种问题，称之为无监督学习。
- 例如，聚类
 - K-Means
 - 层次聚类





半监督学习

- 半监督学习使用大量的未标记数据，以及同时使用标记数据，来进行模式识别工作。




$$\frac{A}{r} = \pi r^2$$



强化学习

- 强化学习(reinforcement learning), 又称再励学习、评价学习, 是一种重要的机器学习方法, 在智能控制机器人及分析预测等领域有许多应用。



目录 CONTENTS



01

NLP
机器学习流
程

02


NLP
常见机器学
习方法

03

NLP
文本分类应
用


文本分类

- 二分类：如垃圾邮件标注为“是、否”
- 多分类：词性标注“名词、动词、形容词”等



文本分类

- 主题分类（垃圾邮件）



特征提取feature extraction

- 每个分词视为一个特征
 - 统计信息。例如，TF，IDF，PCA，SVD等。
 - N-gram。
- Feature extraction是在原有特征基础之上创造、凝练出一些新的特征出来。





特征选择feature selection

- Feature selection则只是在原有特征上进行筛选。
- 特征选择的目标大致如下：
 - 提高预测的准确性
 - 构造更快、消耗更低的预测模型
 - 能够对模型有更好的理解和解释





特征选择

- 引用自吴军《数学之美》上的一句话：一个正确的数学模型应当在形式上是简单的。
- 构造机器学习的模型的目的是希望能够从原始的特征数据集中学习出问题的结构与问题的本质，当然此时的挑选出的特征就应该能够对问题有更好的解释。



标注 (tagging)

- 数据标注行业，一个因为人工智能崛起而新兴的行业。



$$A = \pi r^2$$



标注 (tagging)

- 数据标注市场目前有下面几种结构：

- 众包结构
 - 需要拥有大量的志愿者基数
 - 沟通成本高昂
 - 数据保密困难
 - 无法给予需求公司灵活的服务
- 工厂结构
 - 选择标注公司的困难
 - 工厂结构公司两极分化
 - 人工成本风险较高

Amazon Mechanical Turk


Access a global, on-demand, 24x7 workforce

参考：<https://translate.google.com.hk/?hl=zh-CN>





百度云众包





NLP应用-搜索

Baidu 百度 机器学习 文本分类 自然语言  **百度一下**

[网页](#) [资讯](#) [视频](#) [图片](#) [知道](#) [文库](#) [贴吧](#) [采购](#) [地图](#) [更多»](#)

百度为您找到相关结果约2,990,000个 [搜索工具](#)

[文本分类](#) | [我爱自然语言处理](#)

 属于中文信息处理、情感分析、**文本分类**、**机器翻译**、深度学习、**自然语言处理**、阅读理解分类,被贴了 AI Challenger、AI Challenger 2018、AI Challenger Baseline、AI ...
www.52nlp.cn/category/... - 百度快照

[自然语言处理系列-2-文本分类-传统机器学习方法 - lqk - CSDN博客](#)
2018年9月19日 - 文档**分类**是指给定文档p(可能含有标题t),将文档**分类**为n个类别中的一个或多个,本文以人机写作为例子,针对有监督学习简单介绍传统**机器学习**方法。文档分...
 [CSDN博客号](#) - 百度快照

[奋战聊天机器人\(四\)自然语言处理中的文本分类 - 蜗牛冲... CSDN博客](#)
2017年9月1日 - **文本分类**是**机器学习**在**自然语言处理**中的最常用也是最基础的应用,**机器学习**相关内容可以直接看我的有关scikit-learn相关教程,本节直接涉及nltk中的**机器学习**...
 [CSDN博客号](#) - 百度快照

[基于自然语言处理和机器学习的文本分类及其应用研究](#)
2018年1月22日 - 摘要: 本文讨论了基于**自然语言处理**和**机器学习**的**文本分类**任务,提出了**文本分类**中新的特征降维方法,并结合两种不同的**机器学习**算法,观察了不同的降维方法...
www.wanfangdata.com.cn... - 百度快照

 [基于机器学习的大规模文本分类 百度文库](#)
2018年9月29日 - 随着信息技术的发展,特别是20世纪90年代基于**机器学习**的**文本分类**方法的逐渐成熟,文本自动分类技术在**自然语言处理**、信息组织、内容过滤等领域中开始被广...
 [百度文库](#)  - 百度快照







NLP应用-推荐系统

• 今日头条

澳大利亚是否在5G网络建设上奉行双重标准？陆慷：我也想听听澳政府的解释

2019-04-10 15:58



推荐阅读

德国出租车司机驾车“接龙”示威 抗议网约车抢占市场



视觉中国 · 04-10 19:33

韩国山林大火过火面积达1757公顷

中国新闻网 · 04-10 19:29



俄公寓失火，消防车被困在20米外的泥里动弹不得

环球网 · 04-10 19:28

日本F-35A战机坠毁 防卫相：或影响航空自卫队部署

中国新闻网 · 04-10 19:28


A

$= \pi r^2$



NLP应用-堆栈系统

问答 为什么2G升3G升4G都没什么事，这次升5G闹得这么大动静？



相关推荐



假如中国移动推出5G无限流量，WiFi还有存在的必要吗？

悟空问答 · 232评论 · [相关](#)



中国现在无现金支付非常普遍，那现金到哪里去了，有什么影响？

悟空问答 · 103评论 · [相关](#)



4G还没仔细体验，5G还没用上，6G却“露脸”了，这样真的好吗？

悟空问答 · 147评论 · [相关](#)



如果没有华为海思的麒麟芯片，高通的芯片会不会比现在更贵？

悟空问答 · 14评论 · [相关](#)



为啥华为的手机越卖越贵，反而手机市场份额更高了？华为手机有啥魔力吸引了消费者？

悟空问答 · 288评论 · [相关](#)

$$\frac{A}{r} = \pi r^2$$

序列学习 (Streaming data)

- 语音识别
 - 音->字
 - HMM, CRF
- 文本转语音
 - 字->音 (多音字)
- 机器翻译
 - 百度、谷歌



分类器





朴素贝叶斯 (Naïve Bayesian)

- 设A、B是两个事件，且 $P(A) > 0$ ，称 $P(A|B)$ 是B发生后A发生的条件概率


条件概率

1. 定义

若 Ω 是全集，A、B是其中的事件（子集），P表示事件发生的概率，则

$$P(A|B) = \frac{P(AB)}{P(B)}$$

为事件B发生后A发生的概率。






朴素贝叶斯 (Naïve Bayesian)

乘法定理

设 $P(A) > 0$, 则有 $P(AB) = P(B|A)P(A) = P(A|B)P(B)$.

设 A, B, C 为事件, 且 $P(AB) > 0$, 则有

$$P(ABC) = P(A)P(B|A)P(C|AB).$$



注：当 $P(AB)$ 不容易直接求得时，可考虑利用 $P(A)$ 与 $P(B|A)$ 的乘积或 $P(B)$ 与 $P(A|B)$ 的乘积间接求得。





贝叶斯公式

贝叶斯公式

定义 设 Ω 为试验 E 的样本空间, A 为 E 的事件,
 $B_1, B_2, \dots, B_n$ 为 Ω 的一个划分, 且 $P(A) > 0$,
 $P(B_i) > 0 (i = 1, 2, \dots, n)$, 则

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)}, \quad i = 1, 2, \dots, n.$$





贝叶斯分类

贝叶斯分类

- 定义：设 X 是类标号未知的数据样本。设 H 为某种假定，如数据样本 X 属于某特定的类 C 。对于分类问题，我们希望确定 $P(H|X)$ ，即给定观测数据样本 X ，假定 H 成立的概率。贝叶斯定理给出了如下计算 $P(H|X)$ 的简单有效的方法：

$$P(H|X) = \frac{P(X|H)P(H)}{P(X)}$$

- $P(H)$ 是先验概率，或称 H 的先验概率。 $P(X|H)$ 代表假设 H 成立的情况下，观察到 X 的概率。
- $P(H|X)$ 是后验概率，或称条件 X 下 H 的后验概率。





朴素贝叶斯分类

- 朴素贝叶斯分类的工作过程如下：
- (1) 每个数据样本用一个 n 维特征向量 $X = \{x_1, x_2, \dots, x_n\}$ 表示，分别描述对 n 个属性 $A_1, A_2, \dots, A_n$ 样本的 n 个度量。
- (2) 假定有 m 个类 $C_1, C_2, \dots, C_m$ ，给定一个未知的数据样本 X （即没有类标号），分类器将预测 X 属于**具有最高后验概率（条件 X 下）的类**。也就是说，朴素贝叶斯分类将未知的样本分配给类 C_i ($1 \leq i \leq m$) 当且仅当 $P(C_i | X) > P(C_j | X)$ ，对任意的 $j=1, 2, \dots, m, j \neq i$ 。这样，最大化 $P(C_i | X)$ 。其 $P(C_i | X)$ 最大的类 C_i 称为**最大后验假定**。根据贝叶斯定理

$$P(C_i | X) = \frac{P(X | C_i)P(C_i)}{P(X)}$$





垃圾邮件分类

标题	Spam标签
传递产品价值：《水质分析手册》（第二版）(最新)(2018年)(官方)	是
2019年04月09日 《赤峰学院学报》征稿	是
各种（发）（票）办理 OJOH	是
多功能儿童智能早教机器人，语音问答，海量资源	是
代-開醃標	是
袁居十《中国科技纵横》杂志社 征稿函	否
预约海德堡租车还可抢到最后一刻优惠！锁定好价拼手速！	否
20190408第八周周程表	否
认证成功	否
小心！网易邮箱提醒您防范诈骗邮件	否





逻辑回归

- 与Sigmoid函数有关

- $f(x) = \frac{1}{1+e^{-x}}$

- $y=1$ 的概率分布公式定义为:

- $P(y=1) = p$

- 则, $P(y=0) = 1 - p$

- 离散型随机变量期望值公式:

- $E(y) = 1 \times p + 0 \times (1 - p) = p$





逻辑回归

- 采用线性模型进行分析，分类公式变换如下

- $P(y = 1|x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$

- 概率 p 与因变量往往是非线性的，为了解决该类问题，我们引入了logit变换，使得 $\text{logit}(p)$ 与自变量之间存在线性相关的关系，逻辑回归模型定义如下：

- $\text{logit}(p) = \ln\left(\frac{p}{1-p}\right) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$





逻辑回归

- 通过推导，概率 p 变换如下


$$p = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n)}}$$

- 通过训练，计算各个参数 $\theta_0, \theta_1 \dots \theta_n$ 。



支持向量机SVM

- Support Vector Machine



决策边界实际上构造了2个平行的超平面作为间隔边界以判别样本的分类,所有在上间隔边界上方的样本属于正类,在下间隔边界下方的样本属于负类。两个间隔边界的距离

$$\frac{2}{\|w\|}$$


被定义为边距 (margin), 位于间隔边界上的正类和负类样本为支持向量 (support vector)

$$A = \pi r^2$$



文本聚类

- K-Means



$$A = \pi r^2$$

垃圾邮件分类和新闻分类




- 1 文本分类与聚类的步骤
- 2 任务：垃圾短信分类
- 3 任务：新闻文本聚类



文本分类与聚类的步骤


- 机器学习算法进行文本分类或聚类步骤如下:

- 数据准备 (收集数据、数据清洗)
- 特征提取
- 模型选择与训练
- 模型测试与调参
- 部署模型



$$A = \pi r^2$$

目录



1

文本分类与聚类的步骤

2

任务：垃圾短信分类

3

任务：新闻文本聚类

$$A = \pi r^2$$



任务：垃圾短信分类

- 垃圾短信分类的流程包括以下步骤。
- 数据读取：读取原始短信数据，共有80万条数据。
- 文本预处理：对原始数据进行预处理，对其进行去重、脱敏和分词等操作。
- 词频统计：分别统计垃圾与非垃圾短信的词频，随后绘制相应的词云图。由于原始数据量较大，需要对数据进行采样，共抽取了两万条数据进行训练模型及分类。
- 分类：分别采用两种方式对短信内容进行分类，第一种方式是自定义朴素贝叶斯函数，第二种则是调用Python内置函数实现朴素贝叶斯分类，两种方式的实现步骤基本一致，最终结果将与测试集进行比较，得到模型的分类情况和准确率。
- 模型评价：使用处理好的测试集进行预测，对比真实值与预测值，获得准确率并进行结果分析。





任务：垃圾短信分类


- 垃圾短信的数据读取过程如下。
 - 读取原始短信数据。
 - 数据中的垃圾短信共有80000条，非垃圾短信有720000条。
- 垃圾短信的文本预处理步骤如下。
 - 首先查看数据是否存在缺失值，对其进行去重和脱敏操作。
 - 接着原始数据中的敏感信息用统一字符替换。
 - 通过采用jieba分词切分短信内容，通过自定义词典分词。
 - 然后对分词后的结果过滤停用词。
 - 最后经过处理的数据中有一些无意义的空列表，对其进行删除。






任务：垃圾短信分类

- 垃圾短信词频统计步骤如下。
 - 首先通过自定义函数统计词频。
 - 接着整合得到词汇序列再进行切分，统计每个词出现的频次。
 - 最后分别对垃圾与非垃圾短信绘制词云图。
- 垃圾短信使用MultinomialNB函数步骤如下。
 - 首先划分训练集和测试集。
 - 然后利用训练集生成词库，分别构建训练集和测试集的向量矩阵。
 - 最后通过内置朴素贝叶斯函数预测分类。
- 垃圾短信分类模型评价过程如下。
 - 通过使用处理好的测试集进行预测，对比真实值与预测值，获得准确率并进行结果分析。


$$\frac{A}{r} = \pi r^2$$

目录



4

文本分类与聚类的步骤

5

任务：垃圾短信分类

6

任务：新闻文本聚类

$$A = \pi r^2$$



任务：新闻文本聚类

- 新闻文本聚类的流程包括以下步骤。
- 数据读取：读取文件列表中的新闻文本并给定标签，划分训练集与测试集，读入的每条新闻作为一行，方便后续数据处理及词频矩阵的转化。
- 文本预处理：每个新闻文本进行jieba分词和去除停用词处理，去除文本中无用的停用词，降低处理维度，加快计算速度。
- 特征提取：使用scikit-learn库调用CountVectorizer和TfidfTransformer函数计算TF-IDF值，将文本转为词频矩阵。
- 聚类：根据导入数据类型标签个数，从而定义分类个数，导入训练数据集后通过调用sklearn.cluster训练模型，并保存聚类模型。
- 模型评价：使用处理好的测试集进行预测，对比真实值与预测值，获得准确率并进行结果分析。





任务：新闻文本聚类

- 新闻文本数据读取步骤如下。
 - 首先读取文件列表中的新闻文本并给定标签。
 - 然后划分训练集与测试集，读入的每条新闻作为一行，方便后续数据处理及词频矩阵的转化。
- 新闻文本聚类的文本预处理步骤如下。
 - 首先通过自定义函数seg_word对文本预处理的内容进行封装。
 - 接着每个新闻文本进行jieba分词和去除停用词处理。
 - 然后去除文本中无用的停用词，降低处理维度，加快计算速度。
 - 最后分别进行数据的预处理和后续的特征提取。





任务：新闻文本聚类

- 新闻文本特征提取过程如下。
 - 首先调用CountVectorizer函数将文本中的词语转换为词频矩阵。
 - 接着调用TfidfTransformer函数计算TF-IDF权值并转化为矩阵。
 - 最后分别对垃圾与非垃圾短信绘制词云图。
- 新闻文本聚类过程如下。
 - 首先选取4个数据集，因此，选用4个中心点。
 - 接着进行模型的训练，调用fit函数将数据输入到分类器中，训练完成后保存模型。
 - 最后训练聚类模型并查看模型准确率。
- 新闻文本聚类的模型评价。
 - 首先输入测试数据进行模型训练，计算测试数据的准确率。
 - 最后使用处理好的测试集进行预测，对比真实值与预测值，获得准确率并进行结果分析。


$$\frac{A}{r} = \pi r^2$$



小结

- 本章节主要介绍了文本分类与聚类基本概念如下。
 - 首先介绍了文本挖掘的概念和应用场景。
 - 接着介绍文本分类和文本聚类常用算法。
 - 随后介绍文本分类与聚类的步骤。
 - 最后实现了文本分类与文本聚类对应的Python案例，分别是垃圾短信的分类和新闻文本的聚类。





实验任务

实验一	文章关键词自动提取
实验二	计算网页内容相似度
实验三	电影评论情感分析





实验一 文章关键词自动提取

- 学时：2
- （一）实验类型：设计性
- （二）实验目的：
 1. 掌握中文分词方法的流程和实现方法。
 2. 掌握关键词提取方法的使用方法，在实际数据集上验证算法效果。
- （三）实验内容：
 1. 使用规则分词法或统计分词法对语料库的文本进行处理，训练出分词模型。
 2. 使用分词模型对语料进行分词。
 3. 使用TF-IDF或TextRank或LSA等算法对文章中的分词进行分析，提取出Top-K个关键词。





实验二 计算网页内容相似度

- 学时：2
- （一）实验类型：设计性
- （二）实验目的：
 1. 掌握中文文本向量化的方法。
 2. 理解中文文本向量化的作用，掌握文本向量距离计算方法，在实际数据集上验证算法效果。
- （三）实验内容：
 1. 使用分词工具将网页语料库中的网页内容进行中文分词，并训练词向量和段落向量。
 2. 使用doc2vec和word2vec等方法将内容向量化，然后计算网页相似度。
 3. 统计语料库中的网页的相似度，并将网页进行聚类。





实验三 电影评论情感分析

- 学时：2
- （一）实验类型：设计性
- （二）实验目的：
 1. 掌握自然语言文本情感分析的流程和实现方法。
 2. 理解自然语言处理技术在实际工程应用中的流程和方法。
- （三）实验内容：
 1. 使用分词工具将电影评论文本分词，使用向量化工具将文本向量化。
 2. 根据电影评分，设计算法，计算分词的正向和负向情感值。
 3. 计算测试数据集评论的情感值，验证算法的有效性。





实验要求

- 1.实验报告（模板随后发布在学习通）
- 2.实验报告
 - （一）实验类型：设计性
 - （二）实验目的：
 - 1. 掌握自然语言文本情感分析的流程和实现方法。
 - 2. 理解自然语言处理技术在实际工程应用中的流程和方法。
 - （三）实验内容：
 - 1. 使用分词工具将电影评论文本分词，使用向量化工具将文本向量化。
 - 2. 根据电影评分，设计算法，计算分词的正向和负向情感值。
 - 3. 计算测试数据集评论的情感值，验证算法的有效性。
 - （四）实验步骤
 - （五）总结与体会





(四) 实验步骤

- 1.数据集
- 2.算法
 - 流程图、伪代码、公式等
- 3.源代码（注释）
- 4.实验结果
 - 实验结果


$$A = \pi r^2$$



实验结果

- Confusion Matrix
- 人工评价
- 精度、准确率、召回率等指标





目录

1	情感分析简介
2	情感分析的常用方法
3	任务：基于词典的情感分析
4	任务：基于文本分类的情感分析
5	任务：基于LDA模型的情感分析





情感分析简介

- 文本情感分析是指用NLP、文本挖掘和计算机语言学等方法对带有情感色彩的主观性文本进行分析、处理、归纳和推理的过程。
- 情感分析的发展和快速起步得益于网络上的社交媒体，例如产品评论、论坛讨论、微博、微信的快速发展。
- 自2000年初以来，情感分析已经成长为自然语言处理（NLP）中最活跃的研究领域之一，也在数据挖掘、Web挖掘、文本挖掘和信息检索方面有广泛的应用与研究。





情感分析的主要内容

- 情感分析的主要内容包括：主客观分类、情感分类、情感极性判断等。
- 主客观性文本：指用户对某一件事件、产品、事物的观点和看法，情感分析的对象是主观性文本，文本的主客观分类是情感分析的基础性工作。
- 情感分类：指将一段文本、句子、词语分为喜、怒、哀、乐等类别。
- 情感极性判断：指分析一段文章的总体态度是肯定还是否定，褒义或贬义。





情感分析的主要内容

- 情感分析的前提是将文本中主观与客观句子进行分类。
- 主观性文本是相对于客观性文本而言的一种文本表达形式，主要描述作者对事物、人物、事件等想法或看法。
- 识别出有主观情感的句子之后，才能对主观句子进行极性判断，判断为褒义或贬义。
- 句子的主客观分类能够有效提高文本情感分析的准确度，目前主要通过句子中是否出现情感词或短语模式简单地判断句子的主客观性，客观句子的识别准确率一般为80%左右，而主观句子的识别准确率只有60%左右。





情感分类

- 文本分类是指按照预先定义的类别决定一篇文本的归属的过程。
- 情感分类主要用于判别自然语言文字中表达的观点、喜好以及与感受和态度等相关的信息。





情感分析的主要内容

- 目前情感分类的研究主要有两种方法。
 - **基于情感词典的情感分析**：利用已有语义词典资源构建领域词典，再通过比对情感文本中所包含的正向情感词、负向情感词，标记为正、负整数值作为情感值，同时考虑一些特殊的词性规则、句法结构对情感判断的影响，如否定句、递进句、转折句等。这种方法需要规模较大的情感词典作为分析的基础。
 - **基于机器学习的情感分类**：其关键在于特征选择、特征权重量化、分类器模型这3个要素。特征选择主要有基于信息增益、基于卡方统计、基于文档频率等方法。常见的特征权重量化方式包括布尔权重、词频（TF）、逆文档频率（IDF）、TF-IDF、熵权重等。分类器模型包括朴素贝叶斯、支持向量机、K近邻、神经网络、决策树、逻辑回归等。





情感极性判断

- 情感极性判断就是判断文本内容所反映的正面或负面、肯定或否定、褒义或贬义的色彩。
- 相对于情感分类，情感极性判断是二分类问题，而前者属于多分类问题。极性判断主要包括基于情感词典的方法和基于机器学习的方法。
- 情感极性判断主要集中于情感的词语极性判断和情感文本极性判断两个方面。
- 情感词语极性判断主要有两种研究方向。
- 基于语义词典进行判断。
- 基于大规模语料库进行判断。





情感分析的常见应用

- 情感分析在信息检索、社交网络、舆情监控、语音识别、机器翻译、推荐系统中有着广泛的应用，以下以商品评论、舆情分析和信息预测为例进行介绍。
- 商品评论分析
- 网上购物的兴起，使带有主观色彩的商品评论文本数量迅速增加，其蕴含着大量有商业价值的用户偏好信息，利用对互联网上商品主观性评论信息的挖掘与分析结果，从中提取产品的特征或属性。
- 消费者可以了解人们对某种商品的态度倾向分布，优化购买决策。
- 生产商和销售商可以了解消费者对其商品和服务的反馈信息，以及消费者对自己和对竞争对手的评价，从而改进产品，改善服务，赢得竞争优势。





情感分析的常见应用

- 情感分析在信息检索、社交网络、舆情监控、语音识别、机器翻译、推荐系统中有着广泛的应用，以下以商品评论、舆情分析和信息预测为例进行介绍。


$$\frac{A}{r} = \pi r^2$$



情感分析的常见应用-商品评论分析

- 商品评论分析
- 网上购物的兴起，使带有主观色彩的商品评论文本数量迅速增加，其蕴含着大量有商业价值的用户偏好信息，利用对互联网上商品主观性评论信息的挖掘与分析结果，从中提取产品的特征或属性。
- 消费者可以了解人们对某种商品的态度倾向分布，优化购买决策。
- 生产商和销售商可以了解消费者对其商品和服务的反馈信息，以及消费者对自己和对竞争对手的评价，从而改进产品，改善服务，赢得竞争优势。





情感分析的常见应用-舆情分析

- 舆情分析
- 舆情分析主要是分析民众对热点事件或新闻事件的看法。最具代表性的舆情平台就是微博、微信。
- 这些在线表述的内容对于了解民众对新闻人物和新闻事件的总体评价，掌握当前的舆情信息，特别是热点事件的舆情信息有着重要作用。
- 当前网络舆情对社会的直接影响越来越大，直接关系到网络的信息安全。
- 通过人工手段难以处理网络中出现的海量信息，因此自动化的情感分析技术在该领域的应用非常有实用价值。





情感分析的常见应用-信息预测

- 信息预测
- 信息预测是指根据过去和现在已经掌握的有关某一事物的信息，运用科学的理论和技术，从已知信息推出未知信息，从现有信息导出未来信息，从而对事物的未来发展作出科学预测的方法。
- 一个新事件的发生或者网络上对某个事件的热议都在很大程度上左右着人们的思维和行动。如在总统或议员大选的时候，很多参选者希望通过汇总选民的网络言论来预测自己是否能够获选。
- 情感分析技术可以帮助用户通过对互联网上的新闻、帖子等信息源进行分析，预测某一事件的未来状况。





目录

1

情感分析简介

2

情感分析的常用方法

3

任务：基于词典的情感分析

4

任务：基于文本分类的情感分析

5

任务：基于LDA模型的情感分析





情感分析的常用方法

- 情感分析技术的核心问题是情感分类，判断一段文本中的情感取向，是一种分类问题。
- 一般可以分为两种，一种是正面、负面二分类或正面、中立、负面三分类，另一种是多元分类，是指具有4种以上分类，如四分类有悲伤、忧愁、快乐和兴奋，七分类有高兴、悲伤、喜欢、生气、厌恶、恐惧和惊讶，可以根据实际需要划分情感种类和情感词。
- 情感分析常用方法有3种。
 - 基于情感词典的方法。
 - 基于文本分类的方法。
 - 基于LDA模型的方法。





基于情感词典的方法

- 基于情感词典的方法是在文本中查找相应的情感词、否定词和程度副词，结合情感词典中情感词的得分情况、是否否定和程度级别进行相应的打分，最后得分的总和即为文本的情感分。
- 该方法较大程度上依赖于情感词典的内容，因此，词典的准确性和灵活度对结果会产生较大的影响。
- 情感词：是指主体对某一个客体表达带有强烈情感色彩的评价词语。其有两种属性如下。
- 极性：指情感词表达出的褒贬词义，即正负面情感。
- 强度：指情感的强弱。





基于情感词典的方法

- 情感词典有很多种不同的版本，可以根据自己的需求选择相应的情感词典。本节使用的是基于微博、新闻、论坛等数据来源构建的BosonNLP情感词典，其词典部分内容如表所示。

情感词	情感分值
疼爱	1.86843297836
眉毛	1.86903161791
和睦相处	1.86909683411
小清新	1.87585892189





基于情感词典的方法

- 程度副词：是对一个形容词或者副词在程度上加以限定或修饰的副词。
- 程度副词本身没有任何的情感倾向性，但能够进一步的增强或者减弱情感强度。
- 程度副词不一定能改变情感倾向性的结果，但一定能改变结果的情感倾向程度。
- 否定词：是用来否认一个事实的成立、存在或真实性的。





基于情感词典的方法

- 基于情感词典的情感分析流程如下。
- 对文本进行分词和去停用词，去除跟情感词无关的词语。
- 对分词结果进行分类，找出其中的情感词、程度副词和否定词。
- 计算情感词的得分，得分函数如式所示。

$$\text{score} = w \times \sum_{i=1}^n (s(i) \times p(i))$$

- 其中 w 为权重，默认为1， $s(i)$ 为情感词得分， $p(i)$ 为情感词对应的程度副词和否定词的乘积，程度副词和否定词默认为1。





基于文本分类的方法

- 基于文本分类是采用标注好情感类别的文本进行训练，获得情感分类器，最后对情感分类器进行测试，输出结果为多个概率值，选择概率最高的情感倾向为分类结果。
- 基于文本分类的情感分析流程如下。
 - 特征提取：就是分类对象所展现的部分特点，是实现分类的依据。
 - 文本转化为特征向量：机器学习无法直接将中文文本作为输入数据，在进行分类算法时，需要进行转换。
 - 划分训练集与测试集：训练集用于训练文本，测试集用于测试分类算法的效果。
 - 构建分类器：构建分类器是运用机器学习的算法训练数据集，得出分类器。
 - 验证分类器：使用测试数据集对分类器进行测试，通过比对测试结果，获得测试数据的准确率，分析测试结果，给出改进建议。





基于LDA模型的方法

- 基于主题的文本情感分析主要是通过挖掘用户评论所蕴含的主题，以及用户对这些主题的情感偏好，从而提高文本情感分析的性能。
- 基于主题模型的情感分析流程如下。
 - 评论信息采集与预处理（如网页爬取、中文分词、停用词处理等）。
 - 主题抽取、情感词抽取（可能涉及到情感词典构建）。
 - 主题的情感分类或评分。
 - 主题情感摘要生成（方便用户直接了解主题）。
 - 系统评测。





目录

1

情感分析简介

2

情感分析的常用方法

3

任务：基于词典的情感分析

4

任务：基于文本分类的情感分析

5

任务：基于LDA模型的情感分析





任务：基于词典的情感分析

- 基于情感词典的情感分析是最简单的一种情感分析方法。
- 首先对文档分词，找出文档中的情感词、否定词和程度副词。
- 然后判断每个情感词的前面是否存在否定词及程度副词，将它之前的否定词和程度副词划分为一个组。
- 如果有否定词那么将情感词的情感权值乘以-1，如果有程度副词那么乘以程度副词的程度值。
- 最后对所有组的得分求和，大于0的归于正向，小于0的归于负向。





目录

1

情感分析简介

2

情感分析的常用方法

3

任务：基于词典的情感分析

4

任务：基于文本分类的情感分析

5

任务：基于LDA模型的情感分析





基于朴素贝叶斯分类的情感分析

- 基于文本分类的情感分析步骤如下。
- 将文本转换为特征以及特征提取，读取积极和消极文本数据，并进行分词，对积极词与消极词赋予标签作为特征。
- 划分80%数据作为训练集，剩余20%作为测试集。
- 构建朴素贝叶斯分类器，使用训练集进行训练、使用测试集进行测试并验证其准确率，输出信息量较大的10个特征。
- 输入评论数据对分类器进行验证。





基于朴素贝叶斯分类的情感分析

- 由于语料是来自于只对某个产品的评价，适用的范围也限制于相关内容的文本。
- 如果采用书评评论进行测试，判断正负面情绪可能发生错判，这也是基于机器学习的缺点。
- 由于机器学习的方法依赖于语料库，因此，训练数据尽量使用较为全面的语料库。





基于SnowNlp的情感分析

- SnowNLP是一个Python写的类库，可以方便的处理中文文本内容，并且自带了一些训练好的字典。SnowNLP主要可以进行以下内容的操作。
 - 中文分词、词性标注。
 - 情感分析、文本分类。
 - 转换拼音、繁体转简体。
 - 提取文本关键词、提取摘要。
 - 分割句子、文本相似。





基于SnowNLP的情感分析

- SnowNLP中的情感分析选用的语料是购物类的评论数据，对于购物类评论的情感分析准确率较高。
- 也可以自己构建相关领域的语料库去替换Snownlp中原来的语料库。
- SnowNLP中分类器算法是选用了朴素贝叶斯算法。





目录

1

情感分析简介

2

情感分析的常用方法

3

任务：基于词典的情感分析

4

任务：基于文本分类的情感分析

5

任务：基于LDA模型的情感分析





数据处理


- 在获取数据后，需要对数据进行如下处理。
- 文本去重。
- 语料压缩。
- 短句删除。





模型训练

- LDA可以直接对文本做主题分析，但是文本的正面评价和负面评价会混淆在一起，并且由于分词粒度的影响（否定词或程度副词等），可能在一个主题下生成一些令人迷惑的词语。因此，将文本分为正面评价和负面评价两个数据集，再分别进行LDA主题分析。
- 分别对两个数据集进行分词处理，去停用词后作为LDA主题分析的输入数据。
- 在利用LDA模型进行情感分析中，首先对语句进行SnowNLP情感分析，划分语句的正负面情感倾向。
- 划分正负面情感后，接着对句子分别进行分词、去除停用词的处理。
- 最后对正面负面情感分别建立LDA模型并输入数据进行训练，分别输出3个主题。


$$\frac{A}{r} = \pi r^2$$



结果分析

- 观察正面评价和负面评价输出的主题信息。
- 分别综合正面评价和负面评价的主题关键字。
- 结合商品评论的主题分析结果，对商家提出一些长远性的建议。





小结

- 本章主要介绍了情感分析的基本概念、常用的情感分析方法和电商评论的情感分析。
- 情感分析主要介绍了其主要内容和常见应用。
- 情感分析方法介绍了基于情感词典、基于文本分类和基于LDA模型的3种情感分析方法。
- 通过3种情感分析方法实现情感分析示例。





课后作业

- 1. 预习基于深度学习的问答机器人，结合目前GPT的技术现状，讨论一下问答机器人的应用现状和未来。



THANK YOU

