



佛山大学
FOSHAN UNIVERSITY



计算机与人工智能学院
School of Computer Science and Artificial Intelligence

Section 3

NLP—中文分词

NLP — Chinese Word Segmentation

任课教师：陈荟慧

目录

1	中文分词简介
2	基于规则的分词
3	基于统计的分词
4	中文分词工具jieba库
5	中文分词的应用





中文分词简介

- 在英文中，单词之间以空格为自然分隔符，分词自然地以空格为单位切分，而中文分词则需要依靠一定技术和方法寻找类似英文中空格作用的分隔符。
- 简单来说，中文分词是指将汉字序列按照一定规范、逐个切分为词序列的过程。
例如：北京市民办高中，分词结果：北京市/民办高中。
- 基于规则的分词是中文分词最先使用的方法，随着统计方法的发展，又提出了一些基于统计的分词模型。
 - 基于规则的分词：正向最大匹配法、逆向最大匹配法。
 - 基于统计的分词：隐马尔可夫模型、条件随机场模型。



目录

1	中文分词简介
2	基于规则的分词
3	基于统计的分词
4	中文分词工具jieba库
5	中文分词的应用





基于规则的分词

- 基于规则或词典的分词方法是一种较为机械的分词方法，其基本思想如下。
 - 将待分词语句中的字符串和词典逐个匹配。
 - 找到匹配的字符串则切分，不匹配则减去边缘的某些字符。
 - 从头再次匹配，直至匹配完毕或者没有找到词典的字符串而结束。
- 基于规则分词主要方法如下。
 - 正向最大匹配法（Maximum Match Method，MM法）。
 - 逆向最大匹配法（Reverse Maximum Match Method，RMM法）。
 - 双向最大匹配法（Bi-direction Matching Method，BMM法）。





正向最大匹配法

正向最大匹配法(Maximum Match Method, MM法)基本思想如下。

- 假设有一个待分词中文文本和一个分词词典，词典中最长的字符串长度为 l 。
- 从左至右切分待分词文本的前 l 个字符，然后查找是否有和词典一致的字符串。
- 若匹配失败，则删去该字符串的最后一个字符，仅留下前 $l-1$ 个字符，继续匹配这个字符串，以此类推。
- 如果匹配成功，那么被切分下来的第二个文本成为新的待分词文本，重复以上操作直至匹配完毕。如果一个字符串全部匹配失败，那么逐次删去第一个字符，重复上述操作。





正向最大匹配法

假设待分词文本为“北京市民办高中”，词典为“{“北京市”，“北京市民”，“民办高中”，“天安门广场”，“高中”}”。由词典得到最长字符串的长度为5，具体分词步骤如下。

- 切分待分词文本“北京市民办高中”前5个字符，得到“北京市民办”，在词典中找不到与之匹配的字符串，匹配不成功。
- 删去“北京市民办”的最后一个字符得到“北京市民”，再与词典进行匹配。在词典中找到与之匹配的字符串，匹配成功。此时，将文本划分为“北京市民”“办高中”。
- 将分词后的第二个文本“办高中”作为待分词文本。此时词典中找不到与之匹配的字符串，匹配不成功。
- 删去“办高中”的最后一个字符，匹配失败，直至删去所有字符都没有匹配成功，因此删去“办高中”的第一个字符，匹配“高中”一词成功，将第二个文本划分为“办”、“高中”。
- 正向最大匹配法分词结果：“北京市民”、“办”、“高中”。





逆向最大匹配法

逆向最大匹配法(Reverse Maximum Match Method, RMM法)基本思想如下。

- RMM与MM法原理相反，从右至左匹配待分词文本的后*l*个字符串，查找是否有和词典一致的字符串。
- 若匹配失败，仅留下待分词文本的后*l*-1个词，继续匹配这个字符串，以此类推。
- 如果匹配成功，则被切分下来的第一个文本序列成为新的待分词文本，重复以上操作直至匹配完毕。
- 如果一个词序列全部匹配失败，则逐次删去最后一个字符，重复上述操作。





逆向最大匹配法

同样以待分词文本“北京市民办高中”为例说明逆向最大匹配法，具体分词步骤如下。


- 切分待分词文本“北京市民办高中”后5个字符，得到“市民办高中”，在词典中找不到与之匹配的字符串，匹配不成功。
- 删去“市民办高中”的第一个字符得到“民办高中”，再与词典进行匹配，匹配成功，将文本划分为“北京市”、“民办高中”。
- 将分词后的第一个文本“北京市”作为待分词文本，与词典匹配成功。
- 逆向最大匹配法分词结果：“北京市” “民办高中”。





逆向最大匹配法

逆向最大匹配法中文分词具体流程展示如下图所示。分词结果为：“北京市”“民办高中”。





双向最大匹配法

双向最大匹配法(Bi-direction Matching Method, BMM法)基本思想如下。

- 双向最大匹配法基本思想是将MM法和RMM法的结果进行对比，选取两种方法中切分次数较少的作为切分结果。
- 用正向最大匹配法和逆向最大匹配法对“北京市民办高中”进行分词，结果分别为“北京市民”、“办”、“高中”和“北京市”、“民办”、“高中”。
- 选取切分次数最少的结果为“北京市”、“民办高中”。
- 研究表明，利用正向最大匹配法和逆向最大匹配法匹配，中文分词大约90%的词句完全重合且正确，有9%左右的句子得到的结果不一样，但其中有一个是正确的。剩下不到1%的句子使用两种方法进行切分都是错误的。
- 因而，双向最大匹配法在中文分词领域中得以广泛运用。



目录

1	中文分词简介
2	基于规则的分词
3	基于统计的分词
4	中文分词工具jieba库
5	中文分词的应用





基于统计的分词

- 基于规则的中文分词常常会遇到歧义问题和未登录词问题。
- 中文歧义问题主要包括两大类。
 - 交集型切分歧义：指一个字串中间的某个字或词，不管切分到哪一边都能独立成词，如“折扣”一词，“打折”和“折扣”可以是两个独立的词语。
 - 组合型切分歧义：指一个字串中每个字单独切开或者不切开都能成词，如“将来”一词，可以单独成词，也可以切分为单个字。





基于统计的分词

- 未登录词也称为生词，即词典中没有出现的词，未登录词可以分为四大类。
 - 第一类是日常生活出现的普通新词汇，尤其是网络热门词语，这类词语更新换代快，且不一定符合现代汉语的语法规则；
 - 第二类是专有名词，主要指人名、地名和组织机构名，它还包括时间和数字表达等；
 - 第三类是研究领域的专业名词，如化学试剂的名称等；
 - 第四类是其他专用名词，如近期新上映的电影、新出版的文学作品等。遇到未登录词时，分词技术往往束手无策。





基于统计的分词

- **基于统计的分词方法：有效解决了中文分词遇到歧义问题和未登录词问题。**
 - 基本思想：中文语句中相连的字出现的次数越多，作为词单独使用的次数也越多，语句拆分的可靠性越高，分词的准确率越高。
 - 基本原理：统计词出现的次数，次数足够高的词作为单独的词语被保留。
 - 优势：能够较好地处理未登录词和歧义词，不需要人为的搭建和维护词典。
 - 缺点：需要依靠语料库进行分词，语料库的准确度不一定高，计算量较大，分词速度一般。
 - 两个步骤：建立统计语言模型；运用模型划分语句，计算被划分语句的概率，选取最大概率的划分方式进行分词。
- 常见的基于统计的分词方法有n元语法模型和隐马尔可夫模型。





n元语法模型

- 统计语言模型是描述自然语言内在规律的数学模型，其原理为判断一个句子在文本中出现的概率，是用于计算一个语句序列概率的概率模型。
- 设 S 为一连串特定顺序排列的词序列 $S=\omega_1, \omega_2, \dots, \omega_i$ ， S 的概率记为 $p(\omega_1, \omega_2, \dots, \omega_i)$ 。利用条件概率公式得到如下所示的统计语言模型。
- 其中 ω^{i-1} 表示词序列 $\omega_1, \omega_2, \dots, \omega_{i-1}$ 。

$$\begin{aligned} p(s) &= p(\omega_1)p(\omega_2 | \omega_1) \cdots p(\omega_n | \omega_1, \omega_2, \dots, \omega_{l-1}) \\ &= \prod_i^l p(\omega_i | \omega_1, \omega_2, \dots, \omega_{i-1}) \\ &= \prod_i^l p(\omega_i | \omega^{i-1}) \end{aligned}$$





n元语法模型-什么是n-gram模型

- 在上页所示的统计语言模型中，当词序列长度的增加，计算难度将逐渐加大，因此需要借助近似方法计算 $p(s)$ 。为解决该问题，提出了马尔可夫假设。
- 设 $\omega_1, \omega_2, \dots, \omega_i$ 为一连串特定顺序排列的词序列，马尔可夫假设 ω_i 出现的概率只与前面 $N-1$ 个词 $\omega_{i-N+1}, \dots, \omega_{i-2}, \omega_{i-1}$ 相关。当 $N=n$ 时，称为 **n元语法模型** (n-gram Model)。
 - 当 $N=1$ 时，称为一元语法模型 (unigram模型)， $p(s)$ 的概率如下所示。

$$p(\omega_1, \omega_2, \dots, \omega_l) = p(\omega_1) p(\omega_2) \cdots p(\omega_l)$$

- 当 $N=2$ 时， ω_i 出现的概率只与前面1个词 ω_{i-1} 相关，称为二元语法模型 (bigram模型)， $p(s)$ 的概率如下所示。

$$p(\omega_1, \omega_2, \dots, \omega_l) = p(\omega_1) p(\omega_2 | \omega_1) \cdots p(\omega_l | \omega_{l-1})$$


$$A = \pi r^2$$



n元语法模型

- 当 $N=3$ 时， ω_i 出现的概率只与前面2个词 $\omega_{i-2}, \omega_{i-1}$ 相关，称为三元语法模型（trigram模型）， $p(s)$ 的概率如下所示。

$$p(\omega_1, \omega_2, \dots, \omega_l) = p(\omega_1)P(\omega_2 | \omega_1) \cdots p(\omega_l | \omega_{l-2}\omega_{l-1})$$

- 一般情况下， N 取值都很小，应用最多的是三元语法模型，主要原因是由于n-gram模型的空间复杂度是 n 的指数函数，即 $O(|V|^{n-1})$ ，其中 $|V|$ 表示语料中总词数，一般在几万到几十万个。此外使用n-gram模型的时间复杂度也是一个指数函数， $O(|V|^{n-1})$ 。





n元语法模型- n-gram模型的参数估计

- n-gram模型的参数就是条件概率 $p(\omega_i | \omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1})$ 。模型的参数估计也称为模型的训练，n-gram模型的参数表达式如下所示。

$$p(\omega_i | \omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1}) = \frac{p(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i)}{p(\omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1})}$$

- 一般采用最大似然估计（Maximum Likelihood Estimation, MLE）的方法对模型参数进行估计，使用MLE对上式进行估计，如下所示。

$$p_{MLE}(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i) = \frac{c(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i)}{|V|}$$

$$p_{MLE}(\omega_i | \omega_{i-n+1}, \dots, \omega_{i-1}) = \frac{c(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i)}{c(\omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1})}$$

- 上述两个公式中的 $c(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i)$ 和 $c(\omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1})$ 分别表示词语 $\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i$ 和 $\omega_{i-n+1}, \dots, \omega_{i-2}, \omega_{i-1}$ 在语料库中出现的次数。次数越多参数估计的结果越可信。

$$\frac{A}{r} = \pi r^2$$

n元语法模型

- 假设语句序列为 $s=\{\text{小孩, 喜欢, 在家, 观看, 动画片}\}$, 估计这一语句的概率。以二元语法模型为例, 需要检索语料库中每一个词以及和相邻词同时出现的概率。假设语料库中总词数7542, 单词出现的次数如下图所示。



- 语句 s 在当前语料库中出现的概率的计算过程如下式所示。

$$\begin{aligned} p(s) &= p(\text{小孩, 喜欢, 在家, 观看, 动画片}) \\ &= p(\text{小孩})p(\text{喜欢}|\text{小孩})p(\text{在家}|\text{喜欢})p(\text{观看}|\text{在家})p(\text{动画片}|\text{观看}) \\ &= \frac{500}{7542} \times \frac{351}{500} \times \frac{873}{3208} \times \frac{792}{987} \times \frac{170}{801} \approx 0.2122347 \end{aligned}$$

- 语句 s 在当前语料库下出现的概率约为0.2122347。





n元语法模型- 数据平滑

在对统计语言模型的参数进行估计时，常会出现**参数估计公式中分子或分母为零的情况，这种情况称为数据稀疏**。这时需要考虑在模型中结合相应的数据平滑方法解决问题，常用的方法如下

- 加1平滑
- 古德-图灵平滑
- 线性插值平滑等





n元语法模型-数据平滑-加 1 平滑

- (1) 加1平滑
- 加1平滑是最简单、最直观的一种平滑算法。加1平滑规定在训练时任何一个词语在训练语料库都需要至少出现一次（规定没有出现的在语料中也出现一次），这样没有出现过的词语的概率不再是0。加1平滑的公式如式如下所示。

$$p_{\text{add1}}(\omega_i \mid \omega_{i-n+1}, \dots, \omega_{i-1}) = \frac{c(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i) + 1}{c(\omega_{i-n+1}, \dots, \omega_{i-1}) + |V|}$$

- 通过加1平滑后，训练语料库中出现的n-gram的概率不再为0，而是一个大于0的较小的概率值。
- 但在实际的应用中却会出现一些问题，由于总的统计概率一定是1，那么这些后来增加的概率就必然会造成原来概率的减小，而且实验证明，这种概率的减小幅度是巨大的，那么就可能会导致结果的不准确。





n元语法模型-数据平滑-古德-图灵估计

- (2) 古德-图灵估计
- 1953年古德 (I.J.Good) 引用图灵 (Turing) 的方法而提出古德-图灵 (Good-Turing) 估计法，它是很多平滑技术的核心技术。
- 基本思想：是对于没有看见的事件，不能认为它发生的概率就是零，从概率的总量中，分配一个很小的比例给这些没有看见的事件。
- 此时看的见概率总和将会小于1，因此，需要将所有看见的事件概率适当调小。





n元语法模型-数据平滑-古德-图灵估计

- 假设语料库中出现 r 次的词有 N_r 个，特别地，未出现的词数量为 N_0 。设语料库的大小为 N ，如下式所示。

$$N = \sum_{r=1}^{\infty} rN_r$$

- 出现 r 次的词在整个语料库上的相对频度为 r/N ，如果不做任何处理，这个相对频度就是出现 r 次的词的概率估计。
- 现在假设当 r 比较小时，它的估计可能不可靠，因此在计算出现 r 次的词的概率时，要使用一个更小的系数 r^* ，如下所示。

$$r^* = (r + 1) \frac{N_{r+1}}{N_r}$$





n元语法模型-数据平滑-古德-图灵估计

- 由前面两个公式的推导， $p(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i)$ 的古德-图灵估计如下所示。

$$p_{GT}(\omega_{i-n+1}, \dots, \omega_{i-1}, \omega_i) = \frac{r^*}{N}$$

- 为方便理解古德-图灵估计算法，通过一个简单的例子进行介绍。
 - 假设训练集合 $T=\{\text{张三, 喜欢, 外出, 旅行, 李四, 喜欢, 外出, 登山}\}$ ，验证集合 $V=\{\text{王五, 喜欢, 外出, 登山, 不喜欢, 旅行}\}$ 。
 - 训练集合长度为8，验证集合长度为6。在训练集合中，由上一页第二个公式和上式可以得出 $p(\text{喜欢})=p(\text{外出})=0.25$ ，其他词语概率都为0.25。
 - 验证集合中没有在训练集合里出现的词语概率都为0。如果不使用平滑方法处理，那么验证集合中将有词出现概率为0，如 $p(\text{王五})=0$ 。





n元语法模型-数据平滑-古德-图灵估计

利用古德-图灵估计进行平滑需要以下三个步骤。

- 计算发生 r 次的词的数目。发生两次的有“喜欢”、“外出”，没有发生的有“王五”、“不喜欢”，其他各发生一次，即 $N_0 = 2$ ， $N_1 = 2$ ， $N_2 = 2$ ，发生次数大于2的为0。
- 利用古德-图灵法进行平滑，重新计算概率值。发生 $r=0$ 的事件概率为 $p_0 = (0+1) \times \frac{N_{0+1}}{8 \times N_0} = 0.125$ 。发生 $r=1$ 的事件概率为 $p_1 = (1+1) \times \frac{N_{1+1}}{8 \times N_1} = 0.25$ 。发生 $r=2$ 次的事件概率为 $p_2 = (2+1) \times \frac{N_{2+1}}{8 \times N_2} = 0$ ，保持原值0.25。
- 进行归一化处理。3个概率之和为 $2 \times p_0 + 2 \times p_1 + 2 \times p_2 = 1.25$ 。发生0次的词语出现概率为 $0.125/1.25=0.1$ ，1次的词语出现概率率为 $0.25/1.25=0.2$ ，2次的概率为 $0.25/1.25=0.2$ ，这样就避免了概率为0的问题。



n元语法模型-数据平滑-线性插值平滑

- (3) 线性插值平滑
- 线性插值平滑是为高阶n-gram模型提供帮助的一种平滑方法，它利用低阶的n-gram模型对高阶的n-gram模型进行线性插值。
- 如要寻找“西红柿红”一词，但语料库中没有出现过，这时用低阶的n-gram模型替代，即用“西红柿”出现的次数代替。通常在计算概率时，低阶的n-gram模型往往能够更好地反映信息。





n元语法模型-数据平滑-线性插值平滑

- 在一般的简单线性插值中，不管高阶模型是否可行，默认低阶模型和高阶模型都有着相同的权重，这样并不太合理。
- 因此，线性插值平滑中将权重改为 $\lambda(\omega_{i-n+1}, \dots, \omega_{i-1})$ ，以递归的方式改写线性插值法的公式，表示权重是历史的函数，如下式所示。

$$p_{interp}(\omega_i | \omega_{i-n+1}, \dots, \omega_{i-1}) = \lambda(\omega_{i-n+1}, \dots, \omega_{i-1}) P(\omega_i | \omega_{i-n+1}, \dots, \omega_{i-1}) + (1 - \lambda(\omega_{i-n+1}, \dots, \omega_{i-1})) P_{interp}(\omega_i | \omega_{i-n+2}, \dots, \omega_{i-1})$$

- 其中 $\lambda(\omega_{i-n+1}, \dots, \omega_{i-1})$ 可凭借经验设定，也可以通过某些算法确定，但是需要满足条件 $\sum P_{interp}(\omega_{i-n+1}, \dots, \omega_{i-1}) = 1$ 。





n元语法模型-中文分词与n-gram模型

- 设中文句子由字序列 $S = \omega_1, \omega_2, \dots, \omega_n$ 组成，字以不同的方法组合到一起成为词。
S有多种切分，假设 w_j 记为S中的第j种切分， m_j 为第j种切分 w_j 中词的个数，
 $w_j = (w_{j,1}, w_{j,2}, \dots, w_{j,m_j})$ 。中文分词模型就是求字序列 $S = \omega_1, \omega_2, \dots, \omega_n$ 所有切分中概率最大的一种切分 w^* ，如下式所示。

$$w^* = \arg \max_{w_j} p(w_j | s)$$

- 其中， $\arg \max$ 表示式子 $p(w_j | S)$ 达到最大值时变量 w_j 的取值。
- 由贝叶斯公式可得

$$p(w_j | s) = \frac{p(w_j s)}{p(s)} = \frac{p(w_j) p(s | w_j)}{p(s)} \quad \circ$$





n元语法模型

- 由于概率模型是基于语料构建的，当给定字序列 $S = \omega_1, \omega_2 \dots, \omega_n$ ，上页第二个公式中 $p(s)$ 的值是确定的。另一方面，如果 w_j 确定了，则 S 字序列唯一确定，因此条件概率 $p(s|w_j)=1$ 。经由上页两个公式可得。

$$w^* = \underset{w_j}{\operatorname{argmax}} p(w_j|s) = \underset{w_j}{\operatorname{argmax}} p(w_j)$$

- 由统计语言模型（第十五页中的公式）可得。

$$p(w_j) = \prod_i^{m_j} p(w_{j,i}|w_j^{i-1}) \propto \sum_i^{m_j} \log(p(w_{j,i}|w_j^{i-1}))$$





n元语法模型

- 由上页中的两个公式合并可得。

$$w^* = \operatorname{argmax}_{w_j} \sum_{i=1}^{m_j} \log \left(p(w_{j,i} | w_j^{i-1}) \right)$$

- 中文分词实际是对上式求最优解 w^* 的过程。特别的，对于二元语法模型，对上式进行简化可得下式。

$$w^* = \operatorname{argmax}_{w_j} \sum_{i=1}^{m_j} \log \left(p(w_{j,i} | w_{j,i-1}) \right)$$





隐马尔可夫模型

- 隐马尔可夫模型 (Hidden Markov Model, HMM) 是一种概率模型，用于解决序列预测问题，可以对序列数据中的上下文信息进行建模。HMM用于描述含有隐含未知参数的马尔可夫过程。
- 在HMM中，有两种类型的节点，分别为观测序列与状态序列。状态序列是不可见的，它们的值是需要通过从观测序列进行推断而得到的。很多现实应用可以抽象为此类问题，如语音识别、NLP中的分词、词性标注、计算机视觉中的动作识别等。





马尔可夫模型

- 马尔可夫模型描述的是一类典型的随机过程。所谓随机过程就是随时间而随机变化的过程。这种模型可以计算出系统每一时刻处于各种状态的概率以及这些状态之间的转移概率。
- 设一个系统有有限个状态 $S = \{S_1, S_2, \dots, S_N\}$ 。随着时间推移，该系统将从某一状态转移到另一状态。从1时刻开始到 T 时刻为止，系统所有时刻的状态值构成一个随机变量序列，如下所示。

$$Q = q_1, q_2, \dots, q_T$$





马尔可夫模型

- 系统在不同时刻可以处于同一种状态，但在任一时刻只能有一种状态。不同时刻的状态之间是有关系的。时刻 t 的状态由它之前时刻的状态决定，即当前时刻 t 处于状态的概率取决于其在时间 $1, 2, \dots, t-1$ 时刻的状态，系统状态的条件概率如下所示。

$$p(q_t/q_1, q_2, \dots, q_{t-1})$$

- 上式中的条件概率要考虑之前所有时刻的状态，计算起来较为复杂，为此需要进行简化。如果假设 t 时刻的状态只与 $t-1$ 时刻的状态有关，与更早的时刻无关，则上式的条件概率可简化为如下所示。

$$p(q_t/q_1, q_2, \dots, q_{t-1}) = p(q_t/q_{t-1})$$

- 上式称为一阶马尔可夫假设，满足这一假设的马尔可夫模型称为一阶马尔可夫模型。





马尔可夫模型

- 设 $t-1$ 时刻的状态为 s_i ， t 时刻的状态为 s_j ，条件概率 $p(q_t|q_{t-1})$ 构成一个 $N \times N$ 的矩阵 A ，称为状态转移概率矩阵，其元素如下所示。

$$a_{ij} = p(q_t = s_j | q_{t-1} = s_i)$$

- 有 N 个状态的一阶马尔可夫过程有 N^2 次状态转移。状态转移概率矩阵的元素满足下式的约束。

$$\sum_{j=1}^N a_{ij} = 1, a_{ij} \geq 0$$

- 上式表示概率值必须在 $[0,1]$ 之间，无论 $t-1$ 时刻的状态值是什么，在下一个时刻 t 一定会转向 N 个状态中的一个，因此它们的转移概率和必须为1。






隐马尔可夫模型

- 马尔可夫模型中的状态是可见的，而HMM的状态则是部分可见。
- HMM描述观测变量和状态变量之间的概率关系。
- 与马尔可夫模型相比，HMM不仅对状态建模，而且对观测值建模。
- 不同时刻的状态值之间，同一时刻的状态值和观测值之间，都存在概率关系。


$$\frac{A}{r} = \pi r^2$$



• 模型符号意义

变量表示	说明
$Q = \{q_1, q_2, \dots, q_n\}$	模型含有 n 个隐状态
$V = \{v_1, v_2, \dots, v_v\}$	观测值的取值范围
$A = [a_{ij}]_{n \times n}$	状态转移概率矩阵, a_{ij} 表示从状态 i 转到状态 j 的概率, 满足 $\sum_{j=1}^n a_{ij} = 1, \forall i$
$O = o_1 o_2 \dots o_L$	长度为 L 的观测序列, o_t 的取值为 V 中某个值
$x = x_1 x_2 \dots x_L$	长度为 L 的隐状态序列, x_t 的取值为 Q 中某个值
$E = [e_{ij}]_{n \times v}$	发射概率矩阵, $e_{ij} = p(o = v_j x = q_i)$ 表示模型隐状态取值 q_i 时观测到 v_j 的概率, 满足 $\sum_{j=1}^v e_{ij} = 1, \forall i$
$\pi = [\pi_1, \pi_2, \dots, \pi_n]$	初始概率分布, π_i 表示马氏链从该状态起始的概率, 满足 $\sum_{i=1}^n \pi_i = 1$



- 给定观测序列 O 和隐状态序列 x 的情况下，联合概率为

- $p(\mathbf{x}, O) = \pi_{x_1} e_{x_1}(o_1) \prod_{t=2}^L e_{x_t}(o_t) a_{x_t x_{t-1}}$

- 隐马尔科夫模型的三种典型问题

- 模型评估问题 (Evaluation)

- 已知模型参数和观测序列，求给定观测序列出现的概率

- 隐状态推断问题 (Decoding)

- 已知模型参数和观测序列，求概率最大的状态序列

- 模型学习问题 (Learning)

- 已知观测序列，估计模型参数，使得在该模型下观测序列出现概率最大





HMM的三类问题

- 当通过五元组中某些已知条件来求未知时，就得到HMM的三类问题：
 - 似然度问题（模型评估）：参数(O, π, A, B)已知的情况下，求(π, A, B)下观测序列 O 出现的概率。(Forward-backward算法)
 - 解码问题（隐状态估计）：参数(O, π, A, B)已知的情况下，求解状态值序列 S 。(viterbi算法)
 - 学习问题：观测序列参数(O)已知的情况下，求解其它参数 (π, A, B)。(Baum-Welch算法)


$$\frac{A}{= \pi r^2}$$



隐马尔可夫模型

(1) 一个HMM示例

- 通过掷骰子的例子说明HMM模型。假设暗室里有3个不同形状的骰子，第一个骰子含有六个面（1~6，记为D6），第二个骰子含有四面体（1~4，记为D4），第三个骰子含有八个面（1~8，记为D8）。假设暗室里的实验员根据某一概率分布随机的挑选一个骰子，然后掷骰子，并向室外的报告投掷的数字结果，重复上述过程。
- 对于暗室外边的人来说，只能观察到投掷的数字结果的序列，而骰子的序列是观察不到的。如连续掷骰子8次，得到数字序列为{3,1,2,4,8,7,3,1}。这一串数字是可见的，也称为可见状态链。除了可见状态链，还有一串隐含状态链，也就是实验员挑选骰子的序列。






隐马尔可夫模型

- HMM中的马尔可夫链，通常是指隐含状态链。隐含状态链中有不同骰子之间的转换概率，即不同隐含状态之间有一个转移概率。这里已知3个骰子任选一个时的概率都是1/3，如D4转换成D6时，概率为1/3，D6转换为D8时，概率也为1/3。当然，也可以人为设定转移概率，使得抽取到不同骰子的概率也不相同，从而形成一个新的隐马尔可夫模型。
- 另一方面，在每一个骰子掷出数字时也有一个概率，即不可见状态和可见状态之间有一个发射概率，如D4掷出数字1~4的概率都是1/4，D8掷出数字1~8的概率都是1/8。同样地，输出概率也可以人为设定，设定某个骰子掷出特定数字时的概率更大或更小。掷骰子过程如下图所示。





$$A = \pi r^2$$




隐马尔可夫模型

(2) 隐马尔可夫模型

- 假设观测序列为 $O = o_1, o_2, \dots, o_T$ ，是直接能观察到的序列（上例中投掷骰子的点数序列）。任一时刻的观测值来自有限的观测集（上例中所有骰子点数的集合），记为 $V = \{v_1, v_2, \dots, v_M\}$ 。
- 隐含状态序列为（上例中选择投掷骰子的序列） $Q = \{q_1, q_2, \dots, q_r\}$ ，这条序列是不可观测的。任一时刻的状态值来自有限的状态集 $S = \{s_1, s_2, \dots, s_N\}$ 。HMM 的结构如下图所示。





$$A = \pi r^2$$



隐马尔可夫模型

一个HMM有以下3个部分组成。

- 设模型中状态的数目为 N (上例中骰子的数目)，每个状态可能输出的观测值的数目为 M (上例中骰子的不同数字的数目)。
- 状态转移概率矩阵如下方第一个公式所示。其中 $a_{ij} = p(q_t = S_j | q_{t-1} = S_i)$ ，表示从一个状态 S_i 转向另一个状态 S_j 的概率，满足第二个公式的条件。

$$A = [a_{ij}]_{N \times N}, \quad 1 \leq i, j \leq N$$

$$\sum_{j=1}^N a_{ij} = 1, a_{ij} \geq 0$$





隐马尔可夫模型

- 任一时刻 t ，从状态 s_j 观察到 v_k 的概率分布矩阵如第一个公式所示。其中 $b_j(v_k) = p(o_t = v_k | q_t = s_j)$ （如掷骰子的例子中实验员选取第 j 个骰子投掷出数字 k 的概率 $b_j(v_k)$ ），满足如第二个公式的条件。其中观测值的概率 $b_j(v_k)$ 又称符号发射概率。

$$B = [b_j(v_k)]_{N \times M}, 1 \leq k \leq M, 1 \leq j \leq N$$

$$\sum_{k=1}^M b_j(v_k) = 1, b_j(v_k) \geq 0, 1 \leq j \leq N$$





隐马尔可夫模型

- 初始时刻的状态概率分布如第一个公式所示。其中， $\pi = (\pi_1, \dots, \pi_N)$ 满足后面3个公式的条件。一般地，一个HMM记为一个五元组 $\lambda = (S, V, A, B, \pi)$ 。为了简单起见，有时也将其记为三元组 $\lambda = (\pi, A, B)$ 。隐藏状态和观测值的数量是根据实际问题人为设定的，状态转移矩阵和发射概率矩阵通过样本学习得到。

$$\pi = (\pi_1, \dots, \pi_N), \quad 1 \leq i \leq N$$

$$\pi_i = P(q_1 = s_i)$$

$$\pi_i \geq 0$$

$$\sum_{j=1}^N \pi_j = 1$$





隐马尔可夫模型

- (3) HMM的两个基本假设
- 齐次马尔可夫性假设。假设隐马尔可夫链在任意时刻 t 的状态只依赖于其前一时刻 $t-1$ 的状态，与其他时刻的状态及观测无关，如下式所示。

$$P(q_t/q_1, o_1, \dots, q_{t-1}, o_{t-1}) = P(q_t/q_{t-1})$$

- 观测独立性假设。任意时刻 t 的观测 o_t 只依赖于该时刻的马尔可夫链 q_t 的状态，与其他观测及状态无关。如下式所示。

$$p(o_t/q_1, o_1, \dots, q_t, o_t) = p(o_t/q_t)$$





隐马尔可夫模型

- (4) HMM中的3个基本问题
- 概率计算问题。给定一个三元组 $\lambda = (\pi, A, B)$ 和观测序列 $O = o_1, o_2, \dots, o_T$, 计算在给定模型 $\lambda = (\pi, A, B)$ 条件下观测序列 O 的概率 $p(O|\lambda)$ 。
- 参数估计问题。已知观测序列 $O = o_1, o_2, \dots, o_T$, 估计模型 $\lambda = (\pi, A, B)$ 参数, 使得在该模型下观测序列概率 $p(O|\lambda)$ 最大。
- 预测问题, 也称解码问题。给定一个三元组 $\lambda = (\pi, A, B)$ 和观测序列 O , 计算最有可能的状态序列 $Q = \{q_1, q_2, \dots, q_r\}$ 。





隐马尔可夫模型-中文分词与HMM

- 中文分词可以看作是中文的标注问题。标注问题是给定观测序列预测其对应的标记序列。
- 假设标注问题的数据是由HMM生成的，利用HMM的学习与预测算法进行标注。
- 下面以中文分词问题为例，介绍HMM如何用于中文标注。对于句子“我是中华人民共和国国民”，在这里观测序列为“我是中华人民共和国国民”，每个字为每个时刻的观测值。





隐马尔可夫模型

- 状态序列为标注的结果，每个时刻的状态值有4种情况{B,M,E,S}，其中B代表该字是起始位置的字，M代表中间位置的字，E代表末尾位置的字，S代表能够单独成字的字。
- 对待分词语句进行序列标注，如果得到状态序列Q为{S S B E B M E}，则有“我/S 是/S 一/B 位/E 程/B 序/M 员/E”。
- 得到了这个标注结果后，即可得到分词结果。遇到S，则为一个单字词，遇到B，则为一个词的开始，直到遇到下一个E，则为一个词的结尾。
- 这样句子“我是中华人民共和国国民”的分词结果为“我/是/中华人民共和国/国民”。





隐马尔可夫模型

- 设 $O = o_1, o_2, \dots, o_T$ 为中文字观测序列, $S = \{s_1, s_2, \dots, s_N\}$ 为待标注的状态, 中文分词问题可描述为求条件概率最大的状态序列 $p(Q|O)$, 如下式所示。

$$Q^* = \operatorname{argmax}_Q p(Q|O)$$

- 根据贝叶斯公式可得。

$$p(Q|O) = \frac{p(Q, O)}{p(O)} = \frac{p(O|Q)P(Q)}{p(O)}$$

由于待标注的字观测序列 $O = o_1, o_2, \dots, o_T$ 已知, 因此 $p(O)$ 为一确定的数, 只需计算最大化情况下的 $p(O|Q)p(Q)$ 。这样, 中文分词问题可描述为如下式所示。

$$Q^* = \operatorname{argmax}_Q p(O|Q)p(Q)$$





隐马尔可夫模型

- 由HMM的两个基本假设可知，每一时刻的观测值只与对应时刻的状态值有关，每一时刻的状态值只与上一时刻的状态值有关，如下二式所示。

$$p(O|Q) = p(o_1|q_1)p(o_2|q_2)\cdots p(o_T|q_T)$$

$$p(Q) = P(q_1)p(q_2|q_1)\cdots p(q_T|q_{T-1})$$

- 其中， $p(q_i|q_{i-1})$ 表示状态转移概率， $p(o_i|q_i)$ 表示发射概率。由上述二式，可得如下公式。

$$p(O|Q)p(Q) = p(q_1)p(o_1|q_1) \times p(q_2|q_1)p(o_2|q_2) \times \cdots \times p(q_T|q_{T-1})p(o_T|q_T)$$

- 因此，上页的第一个公式可以表述为如下公式。

$$Q^* = \operatorname{argmax}_Q \prod_i^T p(q_i|q_{i-1})p(o_i|q_i)$$

- 除了HMM，条件随机场也是基于马尔可夫思想的统计分词算法。HMM假设每个时刻的状态只与前一时刻的状态有关，而条件随机场假设每一时刻的状态还与后一时刻的状态有关。





隐马尔可夫模型-维特比算法


- 维特比算法 (Viterbi algorithm) 是机器学习中应用非常广泛的动态规划算法，在求解HMM模型预测问题中用到该算法。
- 实际上，维特比算法不仅是很多NLP的解码算法，也是现代数字通信中使用最频繁的算法。
- 中文分词问题可以利用维特比算法求解，得到标注的状态序列值。





隐马尔可夫模型

- (1) 动态规划
- 如果一类活动过程可以分为若干个互相联系的阶段，在每一个阶段都需做出决策，一个阶段的决策确定以后，常常影响到下一个阶段的决策，从而能够完全确定一个过程的活动路线，则称此类活动为多阶段决策问题。
- 各个阶段的决策构成一个决策序列，称为一个策略。每一个阶段都有若干个决策可供选择。不同策略的效果也不同。多阶段决策问题，就是要在可以选择的策略中选取一个最优策略，使其在预定的标准下达到最好的效果。
- 多阶段决策问题中，各个阶段采取的决策，一般来说是与时间有关的，决策依赖于当前状态，又随即引起状态的转移，一个决策序列就是在变化的状态中产生出来的，故有“动态”的含义，称这种解决多阶段决策最优化问题的方法为动态规划方法。





隐马尔可夫模型

- 动态规划是运筹学的一个分支，是求解决策过程最优化的数学方法。20世纪50年代初美国数学家理查德·贝尔曼（R.E.Bellman）等人在研究多阶段决策过程的优化问题时，提出了著名的最优化原理，将多阶段过程转化为一系列单阶段问题，利用各阶段之间的关系，逐个求解，创立了解决这类过程优化问题的动态规划方法。
- 动态规划原理：假设最优路径为 $i_1^*, \dots, i_T^*$ ，如果最优路径在时刻 t 通过结点 i_t^* ，那么从结点 i_t^* 到终点 i_T^* 的子路径 $i_1^*, \dots, i_T^*$ 必定是最优的。因为假如不是这样，那么从 i_t^* 到 i_T^* 就有另一条更好的路径存在，如果将它和从 i_t^* 到终点 i_T^* 的路径连接起来，就会形成一条比原来的路径 $i_1^*, \dots, i_T^*$ 更优的路径，这是矛盾的。





隐马尔可夫模型

- (2) 维特比算法
- 由42页最后一个公式可知，求状态序列 $Q^* = q_1^*, q_2^*, \dots, q_T^*$ 对1到T个时刻的状态进行决策，使得该式的值达到最大。
- 这是一个多阶段决策最优化问题，可用动态规划法求解。
- 实际上维特比算法就是用动态规划法求解HMM的预测问题，即用动态规划求概率最大路径。



前向算法步骤

(1) 初值

$$\alpha_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

(2) 递推 对 $t = 1, 2, \dots, T - 1$,


$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N$$

(3) 终止

$$P(O | \lambda) = \sum_{i=1}^N \alpha_T(i)$$

隐马尔可夫模型

- 假设隐马尔可夫链生成的状态随机序列为 $Q = q_1, q_2, \dots, q_r$ ，它的所有可能的状态集合为， $S = \{s_1, s_2, \dots, s_N\}$ 。为简化表示 $\{s_1, s_2, \dots, s_N\}$ ，将状态集合用整数编号 $\{1, 2, \dots, M\}$ 表示。一个隐马尔可夫链可以构造网络结构图，如下图所示。



$$\frac{A}{r} = \pi r^2$$



隐马尔可夫模型

- 维特比算法就是根据隐马尔可夫链构造的网络结构图，用动态规划方法求从时刻1到时刻 T 的概率最大路径。假设 $\delta_{t-1}(i)$ 为 $t-1$ 时刻，HMM沿着某一路径到达状态 s_i ，并输出观测序列 $o_1, o_2, \dots, o_{t-1}$ 的最大概率，由第42页最后一个公式可得。

$$\delta_{t-1}(i) = \max_{q_1, \dots, q_{t-1}} \prod_{k=1}^{t-1} p(q_k | q_{k-1}) p(o_k | q_k)$$

- 由上式可得变量 δ 的递推公式，如下。其中 $i=1, 2, \dots, N$ ， $t=2, \dots, T-1$ 。

$$\begin{aligned} \delta_t(i) &= \max_{q_1, \dots, q_t} \prod_{k=1}^{t-1} p(q_k | q_{k-1}) p(o_k | q_k) * p(q_t = s_i | q_{t-1}) p(o_t | q_t = s_i) \\ &= \max_{1 \leq j \leq N} [\delta_{t-1}(j) * a_{ji}] b_i(o_t) \end{aligned}$$





隐马尔可夫模型

- 为了记录在时刻 t ，HMM通过哪一条概率最大的路径达到状态 s_i ，维特比算法设置另外一个变量 ψ 用于路径记忆，记录该路径上状态的前一个时刻的状态。定义在时刻 t 状态为 s_i 的概率最大路径中前一个时刻的状态如下所示。

$$\psi_t(i) = \operatorname{argmax}_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$





隐马尔可夫模型


(3) 维特比算法步骤

- 初始化。 $\delta_1(i) = \pi_i b_i(o_1), 1 \leq i \leq N$ 。
- 递推计算。 $\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) \cdot a_{ji}] \cdot b_i(o_t), 2 \leq t \leq T, 1 \leq i \leq N$ 。
- 记忆回退路径。 $\psi_t(i) = \operatorname{argmax}_{1 \leq j \leq N} [\delta_{t-1}(j) \cdot a_{ji}] \cdot b_i(o_t), 2 \leq t \leq T; 1 \leq i \leq N$ 。
- 终止。 $i_T^* = \operatorname{argmax}_{1 \leq i \leq N} [\delta_T(i)], p_T^*(i_T^*) = \max_{1 \leq i \leq N} [\delta_T(i)]$ 。
- 路径（状态序列）回溯。 $i_t^* = \psi_{t+1}(i_{t+1}^*), t = T-1, T-2, \dots, 1$



隐马尔可夫模型

- 通过一个的例子说明维特比算法的过程。假定某地区的天气只分为雨天和晴天，初始状态下雨天的概率为0.6，晴天的概率为0.4，两种天气状态之间转移概率和不同天气状态
- 已知该地区3天的天气状况（雨天



所示。

), 请判断这3天的实际

$$A = \pi r^2$$



隐马尔可夫模型

- 由已知条件可知，状态集合为 $S = \{s_1, s_2\} = \{1, 2\}$ ，1表示雨天，2表示晴天；观测序列 $O = o_1, o_2, o_3$ 表示热，温和，凉爽；通过上1页的天气图，可以得到状态转移概率为 $A = \begin{pmatrix} 0.7 & 0.3 \\ 0.4 & 0.6 \end{pmatrix}$ ，发射概率矩阵为 $B = \begin{pmatrix} 0.1 & 0.5 & 0.4 \\ 0.4 & 0.4 & 0.2 \end{pmatrix}$ ，初始概率分布为 $\pi = (0.6, 0.4)$ 。
- 利用维特比算法，分4个步骤解答。
- 初始化。在 $t=1$ 时，对每一个状态 s_i ， $i=1, 2$ ，求观 o_1 测 为热的概率，记此概率 $\delta_1(i)$ ，如下式所示。
$$\delta_1(i) = \pi_i b_i(o_1), \quad i = 1, 2$$
- 由式代入实际数据可得 $\delta_1(1) = 0.6 \times 0.1 = 0.06$ ， $\delta_1(2) = 0.4 \times 0.4 = 0.16$ 。记 $\psi_1(i) = 0$ ， $i = 1, 2$ 。





隐马尔可夫模型

- **递推计算，记忆回退路径。**在 $t=2$ 时，对每一个状态 s_i ， $i = 1, 2$ ，求在 $t=1$ 时状态为 s_j 观测为热，并在 $t=2$ 时状态 s_i 观测 o_2 为温和的最大概率，记此概率为 $\delta_2(i)$ ，如第一个公式所示。

$$\delta_2(i) = \max_{1 \leq j \leq 2} [\delta_1(j) \cdot a_{ji}] \cdot b_i(o_2)$$

- **同时，对每个状态 s_i ， $i=1, 2$ ，记录概率最大路径的前一个状态 s_j ，如第二个公式所示。**

$$\psi_2(i) = \operatorname{argmax}_{1 \leq j \leq 2} [\delta_1(j) a_{ji}], \quad i = 1, 2$$





隐马尔可夫模型

- 通过上页第2个公式，代入数据，可得计算过程如下。

$$\begin{aligned}\delta_2(1) &= \max_{1 \leq j \leq 2} [\delta_1(j) \cdot a_{j1}] \cdot b_1(o_2) \\ &= \max_j \{\delta_1(1) \cdot a_{11}, \delta_1(2) \cdot a_{21}\} \cdot b_1(o_2) \\ &= \max_j \{\delta_1(0.06 \times 0.7, 0.16 \times 0.4)\} \times 0.5 \\ &= 0.032\end{aligned}$$

- 由上页第2个公式可知， $\psi_2(1) = 2$ 同理可以得到。

$$\begin{aligned}\delta_2(2) &= \max_{1 \leq j \leq 2} [\delta_1(j) \cdot a_{j2}] \cdot b_2(o_2) \\ &= \max_j \{\delta_1(1) \cdot a_{12}, \delta_1(2) \cdot a_{22}\} \cdot b_2(o_2) \\ &= \max_j \{\delta_1(0.06 \times 0.3, 0.16 \times 0.6)\} \times 0.4 \\ &= 0.0384\end{aligned}$$

- 则 $\psi_2(2) = 2$ 。





隐马尔可夫模型

- 在 $t=3$ 时，对每一个状态， $i=1,2$ ，求在 $t=2$ 时状态为 s_j 观测为温和的并在 $t=3$ 时状态 s_i 观测 o_3 为凉爽的最大概率，记此概率为 $\delta_3(i)$ ，则可以得到。

$$\delta_3(i) = \max_{1 \leq j \leq 2} [\delta_2(j) a_{ji}] b_i(o_3)$$

$$\psi_3(i) = \arg \max_{1 \leq j \leq 2} [\delta_2(j) a_{ji}], \quad i = 1, 2$$



目录

1	中文分词的简介
2	基于规则的简介
3	基于统计的分词
4	中文分词工具jieba库
5	中文分词的应用





中文分词工具jieba库

- 基于规则或词典、n-gram模型、隐马尔可夫模型、条件随机场模型等分词方法，在实际应用中效果差异并不大。
- 分词技术更多的是以一种分词方法为主，其余分词方法为辅达到更高的分词准确率。
- 最常用的是以基于词典的分词方法为主，以统计分词方法为辅进行中文分词，这种方法既能较好地处理未登录词和歧义词，又能避免词典准确率带来的问题。
- 中文分词工具jieba库就采用了这种方法进行中文分词。





中文分词工具jieba库

- 随着近年来NLP技术的快速发展，自然语言处理中实现中文分词的工具逐渐增多，其中包括Ansj、HanLP和盘古分词等分词工具。
- 由于在实际开发与研究过程中，使用jieba进行中文分词的人员占大多数，使用较为广泛。
- 相比其他分词工具而言，jieba不仅包含分词这一功能，而且提供了许多分词以外的算法。
- jieba使用简单，并且支持Python、R、C++等多种编程语言的实现，对于新手而言是一个较好的入门分词工具。
- 在Github社区上，jieba长期有着较高的活跃度，社区中也有不少jieba分词实例，遇到问题时可以在社区中反馈。






基本步骤

jieba分词结合了基于规则和基于统计的分词方法，分词过程包含3个步骤。

- 基于前缀词典快速扫描词图，搭建可能的分词结果的有向无环图，构成多条分词路径。如待分词语句为“天津市河西区有点远”，词典中出现了“天”字，以“天”开头的词语都会出现，如“天津”、继而出现“天津市”、“天津市河西区”，前缀词典是按照包含前缀词顺序进行的。有向无环图是指所有的分词路径都按照正向的顺序，如果将每一个词语看成一个节点，那么分词路径对应了从第一个字到最后一个字的分词方式，词语之间不能构成一个回路。
- 采用动态规划的方法寻找最大概率路径，从右往左反向计算最大概率，依此类推，得到概率最大的分词路径，作为最终的分词结果。
- 采用HMM模型处理未登录词，借助模型中语句构成的4个状态B、M、E、S推导，最后利用维特比算法求解最优分词路径。





分词模式

- jieba分词支持**精确模式**、**全模式**和**搜索引擎**三种模式。
 - 精确模式采用最精确的方式将语句切开，适用于文本分析。
 - 全模式可以快速地扫描语句中所有可以成词的部分，但无法解决歧义问题。
 - 搜索引擎模式在精确模式的基础上再切分长词，适用于搜索引擎的分词。
- 通过对 “**中文分词是自然语言处理的一部分！**” 采用三种模型进行分词，介绍jieba的分词模式。3种分词模式的结果如下。
 - 全模式： 中文/ 分词/ 是/ 自然/ 自然语言/ 语言/ 处理/ 的/ 一部/ 一部分/ 部分//
 - 精确模式： 中文/ 分词/ 是/ 自然语言/ 处理/ 的/ 一部分/ ！
 - 搜索引擎模式： 中文/ 分词/ 是/ 自然/ 语言/ 自然语言/ 处理/ 的/ 一部/ 部分/ 一部分/ ！





分词模式

- 全模式和搜索引擎模式会打印所有可能的分词结果，精确模式仅输出一种分词，除了一些适合全模式和搜索引擎模式的场合，一般情况下会较多地使用精确模式。
- 这3种模式的分词主要用jieba.cut函数和jieba.cut_for_search函数。
 - jieba.cut函数可输入3个参数，待分词字符串、cut_all参数选择是否采用全模式（默认为精确模式）、HMM参数控制是否使用HMM模型。
 - jieba.cut_for_search函数可输入两个参数。待分词字符串、是否使用HMM模型。



目录

1	中文分词简介
2	基于规则的分词
3	基于统计的分词
4	中文分词工具jieba库
5	中文分词的应用





HMM中文分词

- 使用Python代码实现HMM分词的过程主要包括训练HMM、定义viterbi函数、调用HMM模型与viterbi函数进行分词3个步骤。
- 1. 训练HMM
 - 训练HMM过程定义了train函数，用于在给定语料下，统计并计算各个位置状态的初始概率、转移概率和发射概率。函数train定义了3个用于存放初始概率、转移概率和发射概率的字典，将结果存至json文件当中。训练HMM的过程包含4个步骤。
 - 加载需要的库，输入待分词文本。
 - 读取语料。语料收集了国内2012年6月和7月期间搜狐新闻中国际、体育、社会、娱乐等18个频道的新闻内容，对其进行预处理后存放于trainCorpus.txt文件中，语料中每句话中的每个词都以空格隔开，读取每一行中的词语并标注其位置状态信息，共有B、E、M、S四种位置状态。





HMM中文分词

- 计算概率参数。统计每个出现在词头的位置状态的次数，得到初始状态概率；统计每种位置状态转移至另一种状态的次数，得到转移概率；统计每个位置状态下对应的字以及其出现次数，计算时采用加法平滑，得到其发射概率。
- 存储概率参数。将初始概率、转移概率和发射概率写入json文件当中，dumps函数用于将字典转化为字符串格式，enumerate函数用于将对象组合为一个索引序列。





HMM中文分词

- 2. 定义viterbi函数
- viterbi函数用于实现维特比算法。将待分词文本输入其中，可以得到最大概率时每个字的位置状态序列。viterbi函数包含4个参数，分别是待分词文本、4个位置状态、初始概率、转移概率和发射概率。
- 定义viterbi函数包含以下3个步骤。
 - 对待分词文本的第一个字，计算4个位置状态下的初始状态概率，在当前语料下，寻找每个字在上述发射概率字典中对应的概率值，计算其发射概率。
 - 求解在4个位置状态下，待分词文本中每个字的最大概率位置状态，求得最大概率的位置状态序列。
 - 根据待分词文本末尾字的位置状态，从状态序列中选取其中概率最大的。函数结果将返回最大的概率值和对应的位置状态序列。





HMM中文分词

- 3. 分词
- 分词通过cut函数实现。cut函数的参数text为待分词文本。cut函数利用json库中的loads函数调用已保存的json文件，再调用viterbi算法求得概率最大的状态序列，最后判断待分词文本每个字的位置状态，对文本进行分词并输出结果。
- 需要注意的是每次程序运行结束后，如果需要再次运行时，需要先删除已生成的json文件后再运行程序，否则会继续对原文件写入内容，出现解析错误。





提取新闻文本的高频词

- 如果一个词语在一篇文档中频繁出现并且有意义，说明该词能很好地代表这篇文档的主要特征，这样的词语称为高频词。
- 在单篇文档中是关键词，在类似于新闻的文章是热词。字词的重要性随着它在文档中出现次数的增加而上升，随着它在语料库中出现频率的升高而下降。
- 高频词的提取时常常会遇到两个问题。
- 一是语句之间的标点符号，分词前需要删除。
- 二是类似于“是”“在”“的”等常用的停用词，需要删除。
- 利用jieba提取高频词包含3个步骤，详情如下。
 - 读取news.txt文件。这是一个存放新闻文本的文件，新闻内容来自搜狐新闻。
 - 加载停用词文件stopword.txt，对新闻内容进行jieba分词。
 - 提取出现频次最高的前十个词语，依次输出文档内容、分词后的文档和出现频次最高的十个词语。





小结

本章主要介绍了基于规则的分词方法、基于统计的分词方法以及使用jieba进行分词。

- 首先介绍了基于规则的正向最大匹配法、逆向最大匹配法和双向最大匹配法3种中文分词方法的基本原理，并使用Python实现逆向最大匹配法分词。
- 接着对基于统计的n元语法模型和HMM分词方法的原理进行讲解，使用Python实现基于HMM的分词。
- 最后介绍中文分词工具jieba库的分词模式，通过jieba库完成高频词提取。



END

