



佛山大学
FOSHAN UNIVERSITY



计算机与人工智能学院
School of Computer Science and Artificial Intelligence

Section 4

NLP—词性标注

NLP — Part-of-Speech (POS) tagging

任课教师：陈荟慧

目录



1	词性标注
2	命名实体识别
3	中文命名实体识别



词性标注简介

- 词性标注是指为分词结果中的每个词标注一个词性的过程，也就是确定每个词是名词、动词、形容词或其他词性的过程。
- 中文词性标注相比与英文词性标注有一定的难度，这是因为中文不像英文可以通过词的形态变化判断词的词性。
- 一个中文词可能有多种词性，在不同的句子中表现的意思也大不相同。例如，“学习能使我进步”这句话，“学习”是名词，而“我要好好学习”这句话，“学习”是动词。
- 基于规则的词性标注。
 - 基于规则的标注方法是较早的一种词性标注方法，这种方法需要获取能表达一定的上下文关系及其相关语境的规则库。
 - 一个好的规则库的获取是比较困难的，主要的获取方式是通过人工编制繁杂的语法或语义信息的词典和规则系统，比较费时费力，并且难以保证规则的准确性。





词性标注简介

- **基于统计的词性标注。**
 - 上世纪七十年代末到八十年代初，开始得到应用。具有代表性的是基于统计模型（n元语法模型和马尔可夫转移矩阵）的词性标注系统，通过概率统计的方法进行自动词性标注。
 - 基于统计的方法主要有基于最大熵的词性标注、基于统计最大概率输出的词性标注和基于隐马尔科夫模型（HMM）的词性标注。
 - 基于统计的标注方法会抑制小概率事件的发生，受到长距离搭配上下文的限制，但有时通过规则的方法会更为容易实现。
- **基于规则的标注和基于统计的标注方法在使用的过程中，各有所长，但都存在一些缺陷。因此，就有了将基于规则与统计相结合的词性标注方法，此方法具有效率更高，处理能力强等特点。**





词性标注规范

- 现代汉语中的词性可分为实词和虚词，共有12种词性。实词有名词、动词、形容词等；虚词有副词、介词、连词等。中文词性通常会通过一些简单字母编码对词性进行标注，如动词、名词、形容词分别用“v”、“n”、“adj”表示。
- 事实上，中文的词性标注至今还没有统一的标注标准，使用较为广泛有宾州树库和北大词性标注规范。本书采用北大词性标注规范，部分词性编码如下表所示。

编码	词性名称	注解
n	名词	取英语名词noun的第1个字母
v	动词	取英语动词verb的第一个字母
a	形容词	取英语形容词 adjective的第1个字母
r	代词	取英语代词pronoun的第2个字母，因p已用于介词
m	数词	取英语numeral的第3个字母，n和u已有他用
q	量词	取英语quantity的第1个字母





词性标注规范

- 接上表。

编码	词性名称	注解
d	副词	取adverb的第2个字母，因其第1个字母已用于形容词
p	介词	取英语介词prepositional的第1个字母
c	连词	取英语连词conjunction的第1个字母
u	助词	取英语助词auxiliary
o	拟声词	取英语拟声词onomatopoeia的第1个字母
e	叹词	取英语叹词exclamation的第1个字母





词性标注规范

- 上面展示了部分词性标注的编码及其注解，通过这个标准可以对一些句子段落进行词性标注。
- 句子“在1998年来临之际，我十分高兴地通过中央人民广播电台、中国国际广播电台和中央电视台，向全国各族人民，向香港特别行政区同胞、澳门和台湾同胞、海外侨胞，向世界各国的朋友们，致以诚挚的问候和良好的祝愿！”的标注结果如下图所示。

在/p 1998 年/t 来临/v 之际/f ， /w 我/r 十分/m 高兴/a 地/u 通过/p [中央/n 人民/n 广播/vn 电台/n]nt 、 /w [中国/ns 国际/n 广播/vn 电台/n]nt 和/c [中央/n 电视台/n]nt ， /w 向/p 全国/n 各族/r 人民/n ， /w 向/p [香港/ns 特别/a 行政区/n]ns 同胞/n 、 /w 澳门/ns 和/c 台湾/ns 同胞/n 、 /w 海外/s 侨胞/n ， /w 向/p 世界/n 各国/r 的/u 朋友/n 们/k ， /w 致以/v 诚挚/a 的/u 问候/vn 和/c 良好/a 的/u 祝愿/vn ！ /w



Jieba词性标注


- jieba词性标注是基于规则与统计相结合的词性标注方法。jieba词性标注与其分词的过程类似，利用词典匹配与HMM共同合作完成词性标注。其词性标注流程可概括为以下两个步骤。
 - 如果是汉字，那么将基于前缀词典构建有向无环图，对有向无环图计算最大概率路径，同时在前缀字典中查找所分词的词性。
 - 如果没有找到，那么将其标注为“x”（表示词性未知）。
 - 如果在标注过程中标志为未知，并且该词为未登陆词，那么通过HMM进行词性标注。
 - 如果不是汉字，那么使用正则表达式判断词的类型，并赋予对应的词性，其中“x”表示未知词性，“m”表示数词，“eng”表示英文词。





Jieba词性标注

- jieba词性标注的流程如右图所示。





Jieba词性标注

- 以“去森林公园爬山”为例，jieba词性标注的流程如下。
- 1. 加载离线统计词典。离线统计词典放在chapter\data文件夹下。词典的每一行有3列，第一列是词，第二列是词频，第三列是词性。离线统计词典部分内容如下表所示。

词	词频	词性
1号店	3	n
1號店	3	n
4S店	3	n
A型	3	n
.....		
BB机	3	n
.....		





Jieba词性标注

• 2. 构建前缀词典。

- 通过离线统计词典构建前缀词典。
如统计词典中的词“森林公园”的前缀分别是“森”、“森林”、“森林公”“公园”的前缀是“公”；“爬山”的前缀是“爬”。
- 统计词典中所有的词形成的前缀词典如右表所示。


前缀	词频	词性
去	123402	v
森	742	n
林	8581	ng
公	5628	n
园	1914	zg
爬	4046	v
山	23539	n
森林	5024	n
森林公园	3	n
爬山	117	n

$$A = \pi r^2$$

Jieba词性标注

• 3. 构建有向无环图。

- 首先，基于前缀词典对输入文本“去森林公园爬山”进行切分。对于“去”，没有前缀，没有其他匹配词，划分为单个词；对于“森”，则有“森”“森林”和“森林公园”3种方式；对于“林”也只有一种划分方式；对于“公”，则有“公”“公园”两种划分方式，依次类推，可以得到每个字开始的前缀词的切分式。
- 然后，构建字的映射列表。在jieba分词中，每个字都是通过在文本中的位置标记，因此可以构建一个以每个字开始位置与相应切分的末尾位置构成的映射列表。





Jieba词性标注


- 构成的映射列表如下图所示。

位置	字	映射	注解
0	去	0: [0]	表示0→0映射，即开始位置为0，末尾位置为0对应的词，就是“去”
1	森	1: [1, 2, 4]	表示1→1, 1→2, 1→4的映射，即开始位置为1，末尾位置为分别为1、2、4的词，则有“森”“森林”和“森林公园”这3个词
2	林	2: [2]	2→2
3	公	3: [3, 4]	3→3, 3→4, “公”“公园”
4	园	4: [4]	4→4, “园”
5	爬	5: [5, 6]	5→5, 5→6, “爬”, “爬山”
6	山	6: [6]	6→6, “山”



Jieba词性标注

- 最后，根据映射列表构建有向无环图。对于每一种切分，将相应的首尾位置相连。最终构成一个有向无环图，如下图所示。





Jieba词性标注

- 4. 计算最大概率路径。
 - 得到有向无环图后，每条有向边的权重（用概率值表示）可以通过前缀词典的词频获得。在有向无环图中，从起点到终点存在多条路径，每一条路径代表一种分词结果。
 - 在所有的路径中，需要计算一条概率最大的路径，也就是在所有切分结果中选取概率最大的一种切分。
 - jieba利用动态规划法计算概率最大路径，通过从句子的最后一个字开始倒序遍历句子的每个字的方式，计算不同分词结果的概率对数得分。
 - 得到概率最大路径后，就可获得分词的结果，同时在前缀字典中查找所分词的词性，得到分词后的词性标注。





Jieba词性标注

- jieba词性标注在实际应用中使用psg.cut函数命令实现，不需要另外编写命令。对“去森林公园爬山”进行词性标注输出的结果如下图所示。

```
去 / v<
森林公园 / n<
爬山 / n<
。 / x<
```

- 词性标注结果中“。”被标注为x。因为句号是标点符号的一种，所以被标注为未知词性。
- 在实际应用，一些字典中不存在的词被标注为未知词性“x”，这对词性统计等处理结果会有一定的影响，因此在使用jieba自定义字典时，要尽可能完善词典信息。





大模型训练和推理是否用到词性标注？

- 大模型的训练和推理过程可能会用到词性标注，具体取决于模型的任务和设计。
- 训练过程
 - 作为额外特征：词性标注可以作为一种额外的特征融入到模型训练中。例如，在一些自然语言处理任务中，如命名实体识别、语义角色标注等，词性信息有助于模型更好地理解句子的结构和语义，从而提高模型的性能。通过将词性标注作为特征输入到模型中，可以让模型学习到不同词性的词语在特定任务中的模式和规律。
 - 数据预处理：在对文本数据进行预处理时，词性标注可以帮助对文本进行更细致的分析和处理。例如，在构建词向量或对文本进行分词后，可以根据词性对词语进行分类或筛选，以便更好地组织和表示数据，为后续的训练过程提供更有针对性的信息。





大模型训练和推理是否用到词性标注？

- 推理过程
- 语义理解辅助：在推理阶段，词性标注可以辅助模型对输入文本进行语义理解。当模型需要生成自然语言文本或回答问题时，了解词语的词性可以帮助它更准确地选择合适的词汇和语法结构，生成更符合语法和语义规则的输出。例如，在生成句子时，知道某个词是名词、动词还是形容词，可以指导模型按照正确的语法模式进行词语组合。
- 后处理：在一些任务中，对模型输出进行后处理时，词性标注也可能会发挥作用。例如，在文本生成任务中，可以根据词性信息对生成的文本进行语法检查和修正，提高文本的质量。





大模型训练和推理是否用到词性标注？

- 并非所有的大模型训练和推理都必须使用词性标注。
- 一些基于大规模语料库训练的语言模型，如 GPT 系列，主要通过学习大量的文本数据来捕捉语言的统计规律和语义信息，可能在训练和推理过程中没有显式地使用词性标注作为特征或预处理步骤，但这并不意味着词性标注对它们就毫无意义。
- 在某些特定的应用场景或对模型进行优化时，词性标注等额外的语言知识可能会被引入以进一步提升模型的性能。





佛山大学
FOSHAN UNIVERSITY



计算机与人工智能学院
School of Computer Science and Artificial Intelligence

Section 5

NLP—命名实体识别

NLP — Named Entity Recognition

任课教师：陈荟慧


目录





命名实体识别简介

- 命名实体识别 (Named Entity Recognition, NER) 中的“命名实体”一般是指文本中具有特别意义或指代性非常强的实体。
- 命名实体可分为实体类、时间类和数字类3大类，以及人名、机构名、地名、时间、日期、货币和百分比7小类。
- 命名实体识别在NLP中占有重要地位，它是信息提取、机器翻译和问答系统等应用领域里的基础工具。
- 命名实体识别的任务就是识别出文本中的命名实体，通常分为实体边界识别和实体类别识别两个过程。
- 中文文本中没有类似英文文本中空格之类的显式标示词的边界标示符，也没有英文中较为明显的首字母大写标志的词，这使得中文的实体的边界识别变得更加有挑战性。


$$A = \pi r^2$$



命名实体识别简介

- 中文实体识别的挑战性主要表现在以下3个方面。
- 中文词灵活多变。有些词语在不同语境下可能是不同的实体类型，如中国辽宁有个省市叫“沈阳”，中国也有一些人名叫“沈阳”，同一个词“沈阳”在不同语境下可以是地名或人名。有些词语在脱离上下文语境的情况下无法判断是否为命名实体，特别是一些带有特殊意义的人名如有人取名叫“高富帅”，但“高富帅”在脱离文本的情况下会认为是一个现代流行的形容词。
- 中文词的嵌套情况复杂。一些中文的命名实体中常常嵌套另外一个命名实体。如“北京大学附属中学”这一组织机构名中还嵌套着同样可以作为组织机构名的“北京大学”、地名“北京”。命名实体的互相嵌套情况，对命名实体识别造成一定的困难。
- 中文词存在简化表达现象。通常对一些较长的命名实体词进行简化表达，如“北京大学”通常简化为“北大”，“北京大学附属中学”通常简化为“北大附中”，无疑对命名实体的识别造成一定负担。





命名实体识别简介

- 命名实体识别实际上是序列标注问题。
- 命名实体识别领域常用的3种标注符号B、I、O分别代表实体开始、实体中间、其他。
- 在字一级的识别任务中，对于人名、地名、机构名的3种命名实体PER、LOC、ORG，定义7种标注的集合 $L=\{B\text{-PER}, I\text{-PER}, B\text{-LOC}, I\text{-LOC}, B\text{-ORG}, I\text{-ORG}, O\}$ ，分别代表的是人名、地名、机构名的首部、内部和其他。
- 如“**尼克松**是出身于**加利福尼亚**的政治家”，标注序列为{ **B-PER, I-PER, I-PER, O, O, O, O, B-LOC, I-LOC, I-LOC I-LOC, I-LOC, O, O, O, O** }。





课堂讨论

- 使用HMM方法识别汉族人的姓名


$$A = \pi r^2$$



命名实体识别简介

- 假设 $x = x_1, x_2, \dots, x_n$ 为待标注的字观测序列, $S = \{s_1, s_2, \dots, s_N\}$ 为待标注的状态集合。命名实体识别问题可描述为求概率 $p(y|x)$ 最大的状态序列 $y = y_1, y_2, \dots, y_n$, 其中 $y_i \in S$, 如下式子所示。

$$y^* = \arg \max_y p(y|x)$$

- 早期的命名实体识别主要是基于规则的方法, 后来基于大规模语料库的统计方法逐渐成为主流。HMM、最大熵马尔可夫模型 (Maximum Entropy Markov Model, MEMM) 以及条件随机场 (Conditional Random Field, CRF) 是命名实体识别中最常用也是最基本的3个统计模型。
- 首先出现的是HMM, 其次是MEMM, 最后是CRF。





CRF模型

- CRF模型最早由Lafferty等人于2001年提出，其模型思想主要来源于最大熵模型。
- CRF模型是一种基于统计方法的模型，可以被认为是一个无向图模型或一个马尔可夫随机场，它是一种用于 标记和切分序列化数据的统计框架模型。
- 相对于HMM和MEMM，CRF模型没有HMM那样严格的独立性假设，同时克服了MEMM标记偏置的缺点。
- CRF理论在命名实体词识别、语句分词、词性标注等语言处理领域有着十分广泛深入的应用。
- CRF与HMM不同，CRF中当前的状态不是只由这一时刻观测条件给出，而是与整个序列的整体状态相关，即CRF依赖于自己观测条件下的所有观测数值。
- CRF在解决英语浅层分析、英文命名实体识别等任务时，取得了良好的效果。CRF的特性以及研究成果表明，它也能够适用于中文命名实体识别的研究任务。


$$\frac{A}{r} = \pi r^2$$



CRF模型

- 1. 线性链条件随机场
- 假如一个随机变量序列 $X = X_1, X_2, \dots, X_n$ 中各个节点之间的关系是呈线性的，则称序列 X 是一个线性链。
 - 设 $X = X_1, X_2, \dots, X_n$, $Y = Y_1, Y_2, \dots, Y_n$, 均为线性链表示的随机变量序列。
 - 若在给定的观测序列 X 的条件下，随机变量序列 Y 的条件概率分布 $P(Y|X)$ 满足马尔可夫性，如下式子所示。


$$p(Y_i | X, Y_1, Y_2, \dots, Y_n) = p(Y_i | X, Y_{i-1}, Y_{i+1}), \quad i=1, 2, \dots, n$$

- 则称为 $P(Y|X)$ 线性链条件随机场 (linear-CRF) 。



CRF模型

linear-CRF的结构如下图所示。





CRF模型

• 2. linear-CRF参数化形式

- linear-CRF可以用于文本标注问题。条件概率 $p(Y|X)$ 中， X 表示输入观测序列， Y 表示对应的输出标记序列或状态序列。
- 模型在学习时，利用训练数据通过极大似然估计或正则化的极大似然估计得到条件概率模型 $\hat{p}(Y|X)$ 预测时，对于给定的输入序列 X ，求出条件概率 $p(Y|X)$ 最大的输出序列。
- 如果将 Y 的每一个标注序列当作一个类别，那么可以将序列标注问题看做是多分类问题，即输入观测序列 X ，求出条件概率 $p(Y|X)$ 最大的类别。
- 多分类问题中，多项逻辑斯谛回归是最经典的一类模型，式子如下所示。

$$p(Y = c | X = \mathbf{x}) = \frac{\exp(\omega_c \cdot \mathbf{x})}{\sum_{k=1}^K \exp(\omega_k \cdot \mathbf{x})}, \quad c = 1, 2, \dots, K$$






CRF模型

- 在上述式子中， x 是特征向量， w 为特征向量的权重。
- 因为输入序列 X 一般是一段文本序列，所以机器学习算法是不能直接使用的，需要将它们转化成机器学习算法可以识别的数值特征，然后再交给机器学习的算法进行操作。对于序列标注问题，需要先对输入序列 X 进行特征提取。
- 上页式子可知， $p(Y|X)$ 条件概率分布与节点 X 、 Y_{i-1} 、 Y_i 和 Y_{i+1} 有关，因此，构建的特征函数应该将这些节点信息特征提取出来。选取适当的特征是CRF一项重要任务，特征的选择可直接影响最终标注的质量。
- 设随机变量 X 取值记为 x ， Y 取值记为 y 。序列 X 的特征提取是通过构建特征函数完成的。特征函数包含四个参数，分别为文本 x 、参数 i （表示文本 x 中第 i 个词）、 y_i （第 i 个词的标注值）和 y_{i+1} （第 $i+1$ 个词的标注值）。
- 因为linear-CRF满足马尔科夫性，所以只有上下文相关的局部特征函数，没有不相邻节点之间的特征函数。



CRF模型

特征函数分为两类，第一类是定义在 Y 上的转移特征函数 t ，这类特征函数只和当前节点 y_i 和上一个节点 y_{i-1} 有关,特征函数如下图所示。



$$A = \pi r^2$$



CRF模型

- 第一类特征函数式子如下所示。其中， i 表示当前节点在序列的位置， y_i 表示序列 x 第 i 个字的标注， K_1 是定义在该节点的局部特征函数的总数。

$$t_k(y_{i-1}, y_i, x, i), \quad k = 1, 2, \dots, K_1$$

- 第二类是定义在 Y 节点 y_i 上的状态特征函数 s ，这类特征函数只和当前节点有关特征函数式子如下所示。其中， K_2 是定义在该节点的局部特特征函数的总数。

$$s_l(y_i, x, i), \quad l = 1, 2, \dots, K_2$$





CRF模型

- 需要注意的是两类特征函数是通过人为定义的。特征函数的输出值是0或1，0表示要标注序列不符合这个特征，1表示要标注序列符合这个特征。
- 假设 x = “我去广州旅游”，标注的状态集合为 $S=\{B,I,O\}$ ，分别代表命名实体的开始、实体中间、其他。状态特征函数 s 和转移特征函数 t 可以定义为如下形式。

$$s_1(y_3 = B, x, 3) = \begin{cases} 1, & \text{第3个字“广”标注为B} \\ 0, & \text{其他} \end{cases}$$

$$s_2(y_3 = I, x, 3) = \begin{cases} 1, & \text{第3个字“广”标注为I} \\ 0, & \text{其他} \end{cases}$$

$$s_3(y_3 = O, x, 3) = \begin{cases} 1, & \text{第3个字“广”标注为O} \\ 0, & \text{其他} \end{cases}$$

$$t_1(y_3 = B, y_4 = O, x, 4) = \begin{cases} 1, & \text{第3、4个字“广州”分别标注为B, O} \\ 0, & \text{其他} \end{cases}$$

$$t_2(y_3 = B, y_4 = I, x, 4) = \begin{cases} 1, & \text{第3、4个字“广州”分别标注为B, I} \\ 0, & \text{其他} \end{cases}$$

$$t_3(y_3 = B, y_4 = B, x, 4) = \begin{cases} 1, & \text{第3、4个字“广州”分别标注为B, B} \\ 0, & \text{其他} \end{cases}$$





CRF模型

- 特征函数不限于上述的定义，还可以定义很多。直观上，上述特征函数 t_1 比 t_3 在语料库中出现的可能性更大，理应拥有更大的权重。同理，可以为每个特征函数赋予一个权值，用以表达这个特征函数的重要性。
- 构建完特征函数，即可仿照多项逻辑斯谛回归模型定义linear-CRF的条件概率分布 $p(Y|X)$ 。设 $p(Y|X)$ 为linear-CRF，随机变量 X 取值为 x 的条件下，随机变量 Y 取值为 y 的条件概率分布的定义如下式子所示。

$$p(y|x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$$

- 在上述式子中， $Z(x)$ 的定义如下所示。

$$Z(x) = \sum_y \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right)$$

- 在 $Z(x)$ 的式子中， $t_k(y_{i-1}, y_i, x, i)$ 和 $s_l(y_i, x, i)$ 称为转移特征函数和状态特征函数，特征函数 t_k 和 s_l 取值为1或0。当满足特征条件时取值为1，否则为0。 λ_k 和 μ_k 分别是转移函数和状态函数的权重。





CRF模型

- 3. 特征函数简化形式
- 为了便于描述特征函数，我们将两类特征函数表示为如下式子。

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k = 1, 2, \dots, K_1 \\ s_l(y_i, x, i), & k = l + K_1, l = 1, 2, \dots, K_2 \end{cases}$$

- 对转移与状态特征在各个位置*i* 求和，如下式子所示。

$$f_k(x, y) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i), \quad k = 1, 2, \dots, K_1 + K_2$$

- 用 ω_k 表示特征 $f_k(x, y)$ 的权值，如下式子所示。

$$\omega_k = \begin{cases} \lambda_k, & k = 1, 2, \dots, K_1 \\ \mu_l, & k = l + K_1, l = 1, 2, \dots, K_2 \end{cases}$$





CRF模型

- 随机变量Y取值为y的条件概率分布的定义式子可以表示为如下式子所示。

$$p_{\omega}(y|x) = \frac{1}{Z_{\omega}(x)} \exp \sum_{k=1}^K \omega_k f_k(x, y)$$

- $Z(x)$ 式子可以表示为如下式子所示。其中， $K=K1+K2$ 。

$$Z_{\omega}(x) = \sum_y \exp \sum_{k=1}^K \omega_k f_k(x, y)$$

- 进一步，若用 $F(x, y) = (f_1(x, y), f_2(x, y), \dots, f_K(x, y))$
- T 表示全局特征向量， $\omega = (\omega_1, \omega_2, \dots, \omega_K)^T$ 表示权值向量。上述式子可以表示为内积形式。随机变量Y取值为y的条件概率分布式子的内积形式式子可表示为如下式子所示。

$$p_{\omega}(y|x) = \frac{\exp(\omega \cdot F(x, y))}{Z_{\omega}(x)}$$





CRF模型

- $Z(x)$ 式子的内积形式式子可进一步表示为如下式子所示。

$$Z_{\omega}(x) = \sum_y \exp(\omega \cdot F(x, y))$$





CRF模型

• 4. 条件随机场的参数估计问题

- 随机变量Y取值为y的条件概率分布内积形式的式子和上页式子中，参数 ω 是未知的，linear-CRF模型参数需要通过训练数据进行估计。
- 假定对于训练数据有一组样本集 $D = \{x_j, y_j\}$, $j = 1, 2, \dots, N$ ，其中的样本之间是相互独立的， $\hat{p}(x, y)$ 为训练样本中 (x, y) 的经验概率。对于条件概率模型 $p_\omega(y|x)$ ，训练数据样本集D的对数似然函数如下式子所示。

$$L(\omega) = \sum_{x, y} \hat{p}(x, y) \log p_\omega(y|x)$$

- 由随机变量Y取值为y的条件概率分布式子和Z(x)式子可得如下式子。在式子中， $\omega = (\omega_1, \omega_2, \dots, \omega_K)^T$ 是需要估计的权重参数。

$$\begin{aligned} L(\omega) &= \sum_{x, y} \hat{p}(x, y) \sum_{k=1}^K \omega_k f_k(x, y) - \hat{p}(x, y) \log Z_\omega(x) \\ &= \sum_{j=1}^N \hat{p}(x_j, y_j) \sum_{k=1}^K \omega_k f_k(x_j, y_j) - \hat{p}(x_j, y_j) \sum_{j=1}^N \log Z_\omega(x_j) \end{aligned}$$

$$\frac{A}{r} = \pi r^2$$



CRF模型

- 在上页中，已知训练数据集 D ，由此可知经验概率分布 $\hat{p}(x,y)$ 。
- 可以通过极大化训练数据的对数似然函数求模型参数。
- 具体的优化算法有改进的迭代尺度法、梯度下降法以及拟牛顿法。有兴趣的读者查阅相关资料学习。





CRF模型

- 5. 条件随机场的预测问题

- 预测问题就是给定条件随机场 $p(Y|X)$ 和输入序列 x （观测序列），求条件概率最大的输出序列 y （标记序列），如下式子所示。

$$\begin{aligned} y^* &= \arg \max_y p_{\omega}(y|x) \\ &= \arg \max_y \frac{\exp(\omega \cdot F(x, y))}{Z_{\omega}(x)} \\ &= \arg \max_y \exp(\omega \cdot F(x, y)) \\ &= \arg \max_y \omega \cdot F(x, y) \end{aligned}$$

- 上述式子可以利用动态优化的算法求解，常用的求解方法有Viterb动态优化的方法。



目录



1	词性标注
2	命名实体识别
3	中文命名实体识别



sklearn-crfsuite库简介

- CRFsuite基于C/C++实现了条件随机场模型，可用于快速训练和序列标注。
- sklearn-crfsuite库是基于CRFsuite库的一款轻量级的CRF库，提供了条件随机场的训练、预测和评测方法。该库可兼容sklearn算法，因此可以结合sklearn库的算法设计命名实体识别系统。
- 找到Anaconda Prompt并启动，在命令行输入 “*pip install sklearn-crfsuite*” 命令安装sklearn-crfsuite库。





命名实体识别流程

- 使用sklearn-crfsuite库进行中文命名实体识别，其流程中的步骤包括文本预处理（语料预处理、语料初始化、训练数据），模型训练与预测（模型训练、模型预测）。其中将实现文本预处理步骤的代码定义为CorpusProcess类，模型训练与预测步骤的代码定义为CRF_NER类。
- CorpusProcess类主要实现内容包括语料读取与写入、语料预处理（全角转半角、连接姓名、合并中大粒度分词与时间）、语料初始化（初始化字序列、词性序列、标记序列）、训练数据（窗口统一切分、特征提取）。
- CRF_NER类主要实现的内容包括语料预处理执行、模型定义、模型训练与保存、模型预测。





命名实体识别流程

- 1. 语料预处理
- 本节使用的数据来源于1998年人民日报分词数据集，该数据集中的所有词已经标注了词性，其中部分数据集示例如下图所示。

19980101-01-003-005/m 本报/r 北京/ns 1 2月/t 3 1日/t 讯/Ng 新华社/nt 记者/n 陈/nr 雁/nr 、/w 本报/r 记者/n 何/nr 加正/nr 报道/v : /w 在/p 度过/v 了/u 非凡/z 而/c 辉煌/a 的/u 1 9 9 7年/t , /w 迈向/v 充满/v 希望/n 的/u 1 9 9 8年/t 之际/f , /w ' /w 9 8 /m 北京/ns 新年/t 音乐会/n 今晚/t 在/p [人民/n 大会堂/n]ns 举行/v 。/w 党/n 和/c 国家/n 领导人/n 江/nr 泽民/nr 、/w 李/nr 鹏/nr 、/w 乔/nr 石/nr 、/w 朱/nr 镕基/nr 、/w 李/nr 瑞环/nr 、/w 刘/nr 华清/nr 、/w 尉/nr 健行/nr 、/w 李/nr 岚清/nr 与/p 万/m 名/q 首都/n 各界/r 群众/n 和/c 劳动模范/n 代表/n 一起/s , /w 在/p 激昂/a 奋进/v 的/u 音乐声/n 中/f 辞旧迎新/l 。/w

$$A = \pi r^2$$



命名实体识别流程

- 由于语料中存在格式不统一字符、姓氏与名字分为两个词语等问题，需要对语料进行统一格式化处理，主要包括以下4个内容。
- 将语料全角字符统一转为半角。
- 处理姓名，将姓和名链接在一起。如：江/nr 泽民/nr。
- 处理合并语料库中括号中的大粒度词。如：[人民/n 大会堂/n]ns。
- 处理合并语料库中分开标注的时间。如：12月/t 31日/t。





命名实体识别流程

- 2. 语料初始化
- 语料初始化包括初始化字序列、词性序列，主要是对语料中的句子、词性、实体分类标记进行区分。
- 由词性提取标签。将语料中的时间、人名、组织机构名和地名分别转化为T、PER、ORG和LOC。
- 标签使用BIO模式。本次语料的标签采用“BIO”模式，即实体的第一个字为B_*, 其余字为I_*, 非实体字统一标记为O。
- 此外由于模型采用tri-gram形式，在字符列中，需要在句子前后加上占位符(BOS/EOS)。





命名实体识别流程

- 3. 训练数据
- 训练数据是将经过数据处理后的语料切分为整齐序列并提取相应的特征。
- 窗口切分。将每个特征序按统一的大小切分成整齐序列。
- 特征提取。抽取文本中的字符组合或具有其他意义的标记组成特征，作为特征函数的参数；并通过一组
- 函数完成由特征向数值转换的过程，使特征和一个权值对应。





命名实体识别流程

- 4. 模型训练
- 模型训练由初始化模型参数、数据预处理及模型定义、模型训练3个部分组成。
- 初始化模型参数。定义优化算法、迭代次数及基本模型参数。其中优化算法选用了无约束优化算法L-BFGS,
- 该算法是解无约束非线性规划问题最常用的方法，具有收敛速度快、内存开销少等优点。
- 数据预处理及模型定义。执行数据预处理模块并定义模型。
- 模型训练。划分数据前500行数据为训练集、其余作为测试集，接着进行模型训练，最后将模型结果保存。





命名实体识别流程

- 5. 模型评价
- 模型训练过程中，通过精确率precision (P)、召回率recall (R) 和f1-score (F值) 3项指标评测中文命名实体识别的识别性能及效果。
- 精确率precision (P) 公式如右式所示。
- 召回率recall (R) 公式如右式所示。
- f1-score (F值) 公式如右式所示。
- 在上述的3个公式中，P表示识别出的命名实体中出现在测试结果中的比例，R表示标准结果中被正确识别出的命名实体的比例， N_c 表示正确找出的命名实体数， N_d 表示测试结果中的所有命名实体数， N_t 表示测试集中实际命名实体数。

$$P = \frac{N_c}{N_d} \quad R = \frac{N_c}{N_t} \quad F = 2 \times \frac{P \times R}{P + R}$$





命名实体识别流程

- 模型训练过程中输出测评指标如下图所示。
- 在下图中，LOC、ORG、PER、T分别表示地点、组织机构、人名、时间，precision、recall、f1-score、support则为对应的准确率、召回率、F1值和参与训练样本数。

- 从测评指标结果看，总训练0.904，平均F1值0.928，总3，平均召回率

	precision	recall	f1-score	support
B_LOC	0.944	0.827	0.882	266
I_LOC	0.892	0.801	0.844	1203
B_ORG	0.941	0.913	0.927	682
I_ORG	0.932	0.869	0.899	997
B_PER	0.985	0.918	0.951	440
I_PER	0.983	0.939	0.961	824
B_T	0.993	0.993	0.993	444
I_T	0.995	0.995	0.995	1099
avg / total	0.953	0.904	0.928	5955





命名实体识别流程

- 6. 模型预测
- 模型预测需要先对待预测语料进行数据预处理，然后加载训练完成的模型进行预测，输出语料中存在的命名实体。
- 输入下面两个句子，使用训练好的模型进行预测。
 - “2019年10月1日是一个重要日子，在陕西、江西、广东，村委会服务中心集纳了百姓所需的各类服务：有的干部组织开展农技指导工作，让农产品越种越好；有的商店成为生活驿站，养老金领取、银行存取款、快递包裹寄\取、电商代销代购等都能在这“一站式”解决；有的重点关注老人和儿童，让他'们活动有去处、有事做，为生活增添色彩。”。
 - “1995年，君乐宝乳业集团总裁魏立华创办君乐宝酸奶。凭着对产品质量的孜孜追求，君乐宝乳业迅速成长，2012年销售额达到20亿元。。





命名实体识别流程

- 根据上页输入的句子，模型输出结果如下图所示。

2019 年 10 月 1 日 陕西 江西 广东
1995 年 君乐宝乳业集团 魏立华 2012 年

- 从输出结果可以看出，模型能正确将第一条语料中的时间、地点识别并输出；第二条语料中的时间、公司名称、人名等命名实体能被完全识别并输出，效果最佳；总体上看，该模型的命名实体识别效果较好。
- 对于第一条语料中只有部分命名实体被识别输出，是因为该语料语句较为复杂，更难被识别出。对于这种情况，可以通过丰富训练数据语料库、增加训练次数等方式优化模型，以达到提高模型识别准确率的目的。





小结

本章主要介绍了词性标注和基于条件随机场的命名实体识别。

- 首先介绍了词性标注，重点介绍了基于规则和统计相结合的方法及jieba库的词性标注方法。
- 然后介绍了命名实体识别，着重介绍了条件随机场基本概念和基于条件随机场的命名实体识别的过程。
- 最后利用条件随机场对命名实体识别过程进行讲解。



END

